

Jernbanetransport af passagerer i Danmark

Mathias Andersen, Nicklas Helmundt & Nikolaj Aaby Larsen

2026-06-17

Indholdsfortegnelse

1	Indledning	1
2	Data og dataforberedelse	1
3	Eksplorativ dataanalyse	1
3.1	Tidsserieplot	1
3.2	Sæsonplot	3
3.3	ACF og PACF	4
3.4	Deskriptive statistikker	10
3.5	STL-features: trend- og sæsonstyrke	11
4	Transformation	12
4.1	Box-Cox og Guerrero	12
5	Stationaritet og differentiering	14
6	STL-dekomposition	18
7	Modellering	23
7.1	Træningssplit	23
7.2	Benchmark (SNAIVE)	23
7.3	ETS-modeller	24
7.3.1	Residualanalyse – ETS	24
7.4	ARIMA-modeller	28
7.4.1	Residualanalyse – ARIMA	30
7.4.2	Optimal ARIMA-søgning	34
8	Modelsammenligning	35
8.1	Time series cross validation	40
9	Forecasting og prædiktion	43
10	Sammenfatning og konklusion	46
10.1	Sammenfatning & Konklusion	47

Figuroversigt

1	Jernbanepassagerer	2
2	Log-transformerede jernbanepassagerer	2
3	Sæsonplot	3
4	Subserie-plot	4
5	ACF + PACF – International trafik i alt (log, inkl. corona)	5
6	ACF + PACF – Over Storebælt (log, inkl. corona)	5
7	ACF + PACF – International trafik i alt (log, uden corona)	6
8	ACF + PACF – Over Storebælt (log, uden corona)	7
9	Lag-plot – Over Storebælt (inkl. corona)	8
10	Lag-plot – International trafik i alt (inkl. corona)	8
11	Lag-plot – Over Storebælt (uden corona)	9
12	Lag-plot – International trafik i alt (uden corona)	10
13	Rå vs. log-transformeret inkl. corona	13
14	Rå vs. log-transformeret uden corona	14
15	Differentieringstrin – International trafik i alt	16
16	ACF/PACF – sæsondiff (D=1, lag=4) – International	17
17	ACF/PACF – sæsondiff (D=1, lag=4) – Over Storebælt	18
18	Sæsonjusteret serie – inkl. corona	19
19	Sæsonjusteret serie – uden corona	19
20	STL-dekomposition – inkl. corona (log-skala)	20
21	STL-dekomposition – uden corona (log-skala)	21
22	Fittede værdier og residualer (STL) – inkl. corona	22
23	Fittede værdier og residualer (STL) – uden corona	22
24	Residualer – Auto ETS – International (inkl. corona)	25
25	Residualer – Auto ETS – Over Storebælt (inkl. corona)	26
26	Residualer – Auto ETS – International (uden corona)	26
27	Residualer – Auto ETS – Over Storebælt (uden corona)	27
28	Residualer – Auto ARIMA – International (inkl. corona)	31
29	Residualer – Auto ARIMA – Over Storebælt (inkl. corona)	31
30	Residualer – Auto ARIMA – International (uden corona)	32
31	Residualer – Auto ARIMA – Over Storebælt (uden corona)	33
32	RMSE per forecast-horisont (h=1–4) – inkl. corona	42
33	RMSE per forecast-horisont (h=1–4) – uden corona	43
34	Forecast med prædiktionsintervaller (80% og 95%)	46

Tabeloversigt

1	Deskriptive statistikker inkl. corona	10
2	Deskriptive statistikker inkl. corona	10
3	Deskriptive statistikker uden corona	11
4	Deskriptive statistikker uden corona	11
5	Trend- og sæsonstyrke inkl. corona	11
6	Trend- og sæsonstyrke inkl. corona	11
7	Trend- og sæsonstyrke uden corona	12
8	Trend- og sæsonstyrke uden corona	12
9	Guerrero-optimeret Box-Cox lambda inkl. corona	12
10	Guerrero-optimeret Box-Cox lambda inkl. corona	12
11	Guerrero-optimeret Box-Cox lambda uden corona	12
12	Guerrero-optimeret Box-Cox lambda uden corona	12
13	KPSS-test på log(passagerer) — H0: stationær	14
14	KPSS-test på log(passagerer) — H0: stationær	14
15	Anbefalet antal sæsondifferentieringer (D)	15
16	Anbefalet antal sæsondifferentieringer (D)	15

17	Anbefalet antal ordinære differentieringer (d)	15
18	Anbefalet antal ordinære differentieringer (d)	15
19	Anbefalet d efter sæsondifferentiering (D=1)	15
20	Anbefalet d efter sæsondifferentiering (D=1)	15
21	ETS-modelsammenligning inkl. corona (AICc)	24
22	ETS-modelsammenligning inkl. corona (AICc)	24
23	ETS-modelsammenligning uden corona (AICc)	25
24	ETS-modelsammenligning uden corona (AICc)	25
25	ARIMA-modelsammenligning inkl. corona (AICc)	29
26	ARIMA-modelsammenligning inkl. corona (AICc)	29
27	ARIMA-modelsammenligning uden corona (AICc)	30
28	ARIMA-modelsammenligning uden corona (AICc)	30
29	Optimal ARIMA vs. Auto – inkl. corona (AICc)	35
30	Optimal ARIMA vs. Auto – inkl. corona (AICc)	35
31	Optimal ARIMA vs. Auto – uden corona (AICc)	35
32	Optimal ARIMA vs. Auto – uden corona (AICc)	35
33	Tabel A: ARIMA inkl. corona – træning	36
34	Tabel A: ARIMA inkl. corona – træning	36
35	Tabel B: ARIMA inkl. corona – test	36
36	Tabel B: ARIMA inkl. corona – test	36
37	Tabel C: ETS inkl. corona – træning	37
38	Tabel C: ETS inkl. corona – træning	37
39	Tabel D: ETS inkl. corona – test	37
40	Tabel D: ETS inkl. corona – test	37
41	Tabel E: ARIMA uden corona – træning	38
42	Tabel E: ARIMA uden corona – træning	38
43	Tabel F: ARIMA uden corona – test	38
44	Tabel F: ARIMA uden corona – test	38
45	Tabel G: ETS uden corona – træning	39
46	Tabel G: ETS uden corona – træning	39
47	Tabel H: ETS uden corona – test	39
48	Tabel H: ETS uden corona – test	39
49	Opsummering: Bedste og dårligste model per gruppe	40
50	Opsummering: Bedste og dårligste model per gruppe	40
51	TSCV-modelsammenligning inkl. og uden corona	41
52	TSCV-modelsammenligning inkl. og uden corona	41
53	Forecast og prædiktionsintervaller inkl. corona (80% og 95%)	44
54	Forecast og prædiktionsintervaller uden corona (80% og 95%)	45
55	Sammenfatningsoversigt: Nøgletal per serie og datasæt	47
56	Sammenfatningsoversigt: Nøgletal per serie og datasæt	47

1 Indledning

Denne rapport analyserer kvartalsvise passagertal for jernbanetransport i Danmark. Der fokuseres på to serier: international trafik i alt samt trafik over Storebælt. Formålet er at beskrive serierne, vurdere deres sæson- og trendstruktur og dernæst opbygge og sammenligne prognosemodeller (ETS og ARIMA) med og uden coronaperioden.

2 Data og dataforberedelse

Datasættet indlæses fra Danmarks Statistiks tabel BANE25 og Datasættet dækker perioden 2006k1 til og med 2026k1. Indekset er kvartaler, nøglen (**key**) er trafiktype, og responsvariablen er antallet af passagerer i 1.000. Der udvælges to relevante kategorier: international trafik i alt samt trafik over Storebælt.

```
# Indhentning af data
jernbanedata <- read_excel("data/jernbanetransport af passagerer.xlsx",
                           sheet = "BANE25"
                           )

# Dataforberedelse
# Her forberedes datasættet - Der vælges index, key og respons bliver
# passagerer. Derudover udvælges relevante key-kategorier
jernbanedata <- jernbanedata %>%
  clean_names() %>%
  mutate(kvartal = str_replace(kvartal, "K", "Q")) %>%
  mutate(kvartal = yearquarter(kvartal)) %>%
  filter(key %in% c("International trafik i alt", "Over Storebælt")) %>%
  as_tsibble(index = kvartal, key = key)
```

Der laves også et datasæt uden coronaperioden, da nedlukningerne ikke betragtes som et gentagende fænomen. Her anvendes `forecast::na.interp()` til at udfylde NA-felterne med en lineær interpolation mellem perioden før og efter corona.


```
jernbanedata_corona <- jernbanedata %>%
  filter_index(. ~ "2019 Q4", "2022 Q2" ~ .) %>%
  tsibble::fill_gaps() %>%
  group_by_key() %>%
  mutate(x1000_passagerer = forecast::na.interp(x1000_passagerer)) %>%
  ungroup()
```

3 Eksplorativ dataanalyse

3.1 Tidsserieplot


Der anvendes `autoplot()` til automatisk at skabe et visuelt billede af tidsserien. Her ses et sæsonbetonet mønster for både international trafik i alt og kategorien over Storebælt.

```
# Autoplot af passagertal inkl. corona
kør_begge(function(data, titel) {
  data %>%
    autoplot(x1000_passagerer) +
    labs(title = titel,
         y = "log(1.000 passagerer)",
         x = NULL)
})
```



Figur 1: Jernbanepassagerer

```
kør_begge(function(data, titel) {
  data %>%
    autoplot(log(x1000_passagerer)) +
    labs(title = titel,
         y = "log(1.000 passagerer)",
         x = NULL)
})
```




Figur 2: Log-transformerede jernbanepassagerer

3.2 Sæsonplot

Med `gg_season()` undersøges de underliggende sæsonmønstre, og udviklingen kan ses på årsbasis.

```
kør_begge(function(data, titel) {  
  data %>%  
    gg_season(x1000_passagerer) +  
    labs(title = titel,  
         y = "1.000 passagerer",  
         x = NULL)  
})
```

Warning: ``gg_season()`` was deprecated in feasts 0.4.2.
i Please use ``ggtime::gg_season()`` instead.




Figur 3: Sæsonplot

Sæsonplottene bekræfter et konsistent Q3 peak på tværs af alle år for international trafik. For Over Storebælt er sæsonudslaget mindre synligt, da forskellen mellem Q1 & Q3 er mindre end for international trafik. I det interpolerede datasæt fremstår alle år med næsten parallelle forløb, hvilket vidner om et homogent sæsonmønster uden strukturbrud.

```
kør_begge(function(data, titel) {  
  data %>%  
    gg_subseries(x1000_passagerer) +  
    labs(title = titel,  
         y = "1.000 passagerer",  
         x = NULL)  
})
```

Warning: ``gg_subseries()`` was deprecated in feasts 0.4.2.
i Please use ``ggtime::gg_subseries()`` instead.



Figur 4: Subserie-plot


Begge serier viser et tydeligt sæsonmønster med toppe i tredje kvartal (Q3) og bund i første kvartal (Q1), samt opadgående trend fra 2006 til 2026 med undtagelse af coronaperioden (2020-2021).

3.3 ACF og PACF

ACF måler korrelationen mellem en tidsserie og dens lag-værdier og fortæller, om tidligere observationer kan hjælpe med at forklare de nuværende. PACF viser, hvor mange tidligere værdier der direkte påvirker den nuværende observation; når PACF ikke længere er signifikant, findes AR-ordenen p.


```
jernbanedata %>%
  filter(key == "International trafik i alt") %>%
  mutate(x1000_passagerer = log(x1000_passagerer)) %>%
  gg_tsdisplay(x1000_passagerer, plot_type = "partial", lag_max = 24) +
  labs(title = "ACF + PACF - International trafik i alt (log, inkl. corona)")
```

Warning: `gg\_tsdisplay()` was deprecated in feasts 0.4.2.
i Please use `ggtime::gg\_tsdisplay()` instead.




Figur 5: ACF + PACF – International trafik i alt (log, inkl. corona)

```
jernbanedata %>%
  filter(key == "Over Storebælt") %>%
  mutate(x1000_passagerer = log(x1000_passagerer)) %>%
  gg_tsdisplay(x1000_passagerer, plot_type = "partial", lag_max = 24) +
  labs(title = "ACF + PACF – Over Storebælt (log, inkl. corona)")
```




Figur 6: ACF + PACF – Over Storebælt (log, inkl. corona)


```
jernbanedata_corona %>%
  filter(key == "International trafik i alt") %>%
  mutate(x1000_passagerer = log(x1000_passagerer)) %>%
  gg_tsdisplay(x1000_passagerer, plot_type = "partial", lag_max = 24) +
  labs(title = "ACF + PACF - International trafik i alt (log, uden corona)")
```



Figur 7: ACF + PACF – International trafik i alt (log, uden corona)

```
jernbanedata_corona %>%
  filter(key == "Over Storebælt") %>%
  mutate(x1000_passagerer = log(x1000_passagerer)) %>%
  gg_tsdisplay(x1000_passagerer, plot_type = "partial", lag_max = 24) +
  labs(title = "ACF + PACF - Over Storebælt (log, uden corona)")
```



Figur 8: ACF + PACF – Over Storebælt (log, uden corona)


ACF Plottene for rådata (Log skala) viser lag som, eksponentiel aftagen uden klart cutoff, som er normalt for ikke stationære serier med trend. Signifikante toppe optræder ved lag 4 & 8. (kvartalsvis sæsonperiode)

PACF-plottene afskæres efter lag 1–2 for den ordinære komponent, hvilket indikerer en AR-struktur. For den sæsonale komponent er PACF signifikant ved lag 4 for international trafik, hvilket peger på en sæsonel AR-komponent.

Samlet begrundes dette kandidatmodeller med $ARIMA(p,d,q)(P,D,Q)[4]$, hvor de konkrete ordener bestemmes via stationaritetstest og AICc-sammenligning.


```
kør_begge(function(data, titel) {
  data %>%
    filter(key == "Over Storebælt") %>%
    gg_lag(x1000_passagerer, geom = "point") +
    labs(title = titel,
         x = "lag(x1000_passagerer, k)")
})
```

Warning: `gg\_lag()` was deprecated in feasts 0.4.2.
i Please use `ggtime::gg\_lag()` instead.




Figur 9: Lag-plot – Over Storebælt (inkl. corona)

```
jernbanedata %>%
  filter(key == "International trafik i alt") %>%
  gg_lag(x1000_passagerer, geom = "point") +
  labs(x = "lag(x1000_passagerer, k)")
```



Figur 10: Lag-plot – International trafik i alt (inkl. corona)

```
jernbanedata_corona %>%
  filter(key == "Over Storebælt") %>%
  gg_lag(x1000_passagerer, geom = "point") +
  labs(x = "lag(x1000_passagerer, k)")
```




Figur 11: Lag-plot – Over Storebælt (uden corona)

```
jernbanedata_corona %>%
  filter(key == "International trafik i alt") %>%
  gg_lag(x1000_passagerer, geom = "point") +
  labs(x = "lag(x1000_passagerer, k)")
```

Tabel 1: Deskriptive statistikker inkl. corona

Tabel 2: Deskriptive statistikker inkl. corona

key	N	mean	median	sd	Q1	Q3	min	max
International trafik i alt	81	3075,8	3049	892,9	2654	3528	619	5315
Over Storebælt	81	2019,4	2061	300,7	1945	2177	738	2568



Figur 12: Lag-plot – International trafik i alt (uden corona)

3.4 Deskriptive statistikker

Følgende metrikker giver hurtigt et overblik over fordelingen af passagertal for hver serie.

```
jernbanedata %>%
  as_tibble() %>%
  group_by(key) %>%
  summarise(
    N      = sum(!is.na(x1000_passagerer)),
    mean   = mean(x1000_passagerer, na.rm = TRUE),
    median = median(x1000_passagerer, na.rm = TRUE),
    sd     = sd(x1000_passagerer, na.rm = TRUE),
    Q1     = quantile(x1000_passagerer, 0.25, na.rm = TRUE),
    Q3     = quantile(x1000_passagerer, 0.75, na.rm = TRUE),
    min    = min(x1000_passagerer, na.rm = TRUE),
    max    = max(x1000_passagerer, na.rm = TRUE)
  ) %>%
  kbl(caption = "Deskriptive statistikker inkl. corona", digits = 1,
      booktabs = TRUE)
```

```
jernbanedata_corona %>%
  as_tibble() %>%
  group_by(key) %>%
```

Tabel 3: Deskriptive statistikker uden corona

Tabel 4: Deskriptive statistikker uden corona

key	N	mean	median	sd	Q1	Q3	min	max
International trafik i alt	81	3287,9	3237	677,9	2879	3584,2	1696	5315
Over Storebælt	81	2104,4	2108	147,7	2023	2177,0	1820	2568

Tabel 5: Trend- og sæsonstyrke inkl. corona

Tabel 6: Trend- og sæsonstyrke inkl. corona

key	trend_strength	seasonal_strength_year	seasonal_peak_year	seasonal_trough_year	sp
International trafik i alt	0,965	0,813	3	1	11
Over Storebælt	0,866	0,513	0	1	1

```

summarise(
  N      = sum(!is.na(x1000_passagerer)),
  mean   = mean(x1000_passagerer, na.rm = TRUE),
  median = median(x1000_passagerer, na.rm = TRUE),
  sd     = sd(x1000_passagerer, na.rm = TRUE),
  Q1     = quantile(x1000_passagerer, 0.25, na.rm = TRUE),
  Q3     = quantile(x1000_passagerer, 0.75, na.rm = TRUE),
  min    = min(x1000_passagerer, na.rm = TRUE),
  max    = max(x1000_passagerer, na.rm = TRUE)
) %>%
kbl(caption = "Deskriptive statistikker uden corona", digits = 1,
     booktabs = TRUE)

```

International trafik i alt viser et gennemsnit på 3076 passagerer og en varianskoefficient på 29% (SD=893), med et spænd fra 619 til 5.315 drevet af coronanedgangen. Over storebælt er trafikken væsentlig mere stabil: Gennemsnit 2.019 og varianskoefficient på 15% (SD=301).

Den markant større spredning i International Trafik begrundes anvendelse af en varians stabiliserende transformation, samt opdeling i 2 separate datasæt.

3.5 STL-features: trend- og sæsonstyrke

Her beregnes trend- og sæsonstyrke. De hjælper med at argumentere for, hvilke modelkomponenter der er nødvendige. En høj sæsonstyrke betyder eksempelvis, at en sæsonel model (SARIMA eller ETS med sæson) er påkrævet.

```

jernbanedata %>%
  features(x1000_passagerer, feat_stl) %>%
  kbl(caption = "Trend- og sæsonstyrke inkl. corona", digits = 3,
      booktabs = TRUE)

```

```

jernbanedata_corona %>%
  features(x1000_passagerer, feat_stl) %>%
  kbl(caption = "Trend- og sæsonstyrke uden corona", digits = 3,
      booktabs = TRUE)

```

STL features bekræfter de visuelle observationer kvantitativt. International trafik i alt har høj trend styrke (0,965 & 0,962 inkl/ekskl. corona) og sæsonstyrke (0,813/0,856) hvor coronaperioden kun dæmper sæsonmønstret minimalt. Over storebælt er effekten mere markant, trend styrken stiger fra 0,866 til 0,908 og sæsonstyrken øges

Tabel 7: Trend- og sæsonstyrke uden corona

Tabel 8: Trend- og sæsonstyrke uden corona

key	trend_strength	seasonal_strength_year	seasonal_peak_year	seasonal_trough_year
International trafik i alt	0,962	0,856	3	1
Over Storebælt	0,908	0,800	0	1

Tabel 9: Guerrero-optimeret Box-Cox lambda inkl. corona

Tabel 10: Guerrero-optimeret Box-Cox lambda inkl. corona

key	Lambda_Guerrero
International trafik i alt	0,855
Over Storebælt	2,000

fra 0,513 til 0,800 uden corona. Dette betyder at pandemiens ekstreme udsving indikerer at sæsonkomponenter er nødvendige i både ETS & SARIMA.

4 Transformation

4.1 Box-Cox og Guerrero

Guerrero-metoden finder automatisk den optimale lambda-værdi. Box-Cox er en transformation, der stabiliserer variansen i serien og styres af lambda; herved bliver udslagene lige store gennem hele perioden.

```
jernbanedata %>%
  features(x1000_passagerer, features = guerrero) %>%
  rename(Lambda_Guerrero = lambda_guerrero) %>%
  kbl(caption = "Guerrero-optimeret Box-Cox lambda inkl. corona",
      digits = 3, booktabs = TRUE)

jernbanedata_corona %>%
  features(x1000_passagerer, features = guerrero) %>%
  rename(Lambda_Guerrero = lambda_guerrero) %>%
  kbl(caption = "Guerrero-optimeret Box-Cox lambda uden corona",
      digits = 3, booktabs = TRUE)
```

Guerrero metoden estimerer inkl. corona en lambda på 0,855 (international) og Lambda 2,00 (storebælt). Disse værdier er dog kunstigt oppustede af coronaperiodens udsving, og er ikke repræsentative for den underliggende varians struktur. Det corona rensede datasæt giver et mere retvisende billede med lambda -0,606 (international) og -0,051 (Storebælt), hvor storebælt er tæt på 0, og dermed understøtter log transformation. Log transformationen fastholdes konsekvent for begge serier i al efterfølgende modellering og fable tilbagekalkulerer automatisk til originalskala ved forecast


Tabel 11: Guerrero-optimeret Box-Cox lambda uden corona

Tabel 12: Guerrero-optimeret Box-Cox lambda uden corona

key	Lambda_Guerrero
International trafik i alt	-0,606
Over Storebælt	-0,051

```
bind_rows(
  jernbanedata %>%
    as_tibble() %>%
    mutate(type = "Rå passagertal"),
  jernbanedata %>%
    as_tibble() %>%
    mutate(x1000_passagerer = log(x1000_passagerer),
           type = "log(passagerer)")
) %>%
  ggplot(aes(x = kvartal, y = x1000_passagerer)) +
  geom_line() +
  facet_grid(type ~ key, scales = "free_y") +
  labs(title = "Rå vs. log-transformeret inkl. corona",
       y = NULL, x = NULL)
```

Rå vs. log-transformeret inkl. corona



Figur 13: Rå vs. log-transformeret inkl. corona


```
bind_rows(
  jernbanedata_corona %>%
    as_tibble() %>%
    mutate(type = "Rå passagertal"),
  jernbanedata_corona %>%
    as_tibble() %>%
    mutate(x1000_passagerer = log(x1000_passagerer),
           type = "log(passagerer)")
) %>%
  ggplot(aes(x = kvartal, y = x1000_passagerer)) +
  geom_line() +
  facet_grid(type ~ key, scales = "free_y") +
  labs(title = "Rå vs. log-transformeret uden corona",
       y = NULL, x = NULL)
```


Tabel 13: KPSS-test på $\log(\text{passagerer})$ — H_0 : stationær

Tabel 14: KPSS-test på $\log(\text{passagerer})$ — H_0 : stationær

key	kpss_stat	kpss_pvalue
International trafik i alt	0,1865	0,1
Over Storebælt	0,2156	0,1

Rå vs. log-transformeret uden corona



Figur 14: Rå vs. log-transformeret uden corona

5 Stationaritet og differentiering

KPSS-testen afgør, om en tidsserie er stationær. Nulhypotesen er, at serien er stationær; en p-værdi under 0,05 indikerer, at differentiering er nødvendig.

```
jernbanedata %>%
  features(log(x1000_passagerer), unitroot_kpss) %>%
  kbl(caption = "KPSS-test på log(passagerer) - H0: stationær",
      digits = 4, booktabs = TRUE)
```

`nsdiffs` angiver, hvor mange sæsondifferentieringer (D) der er nødvendige for at gøre serien stationær. Returneres 1, skal der sæsondifferentieres for at fjerne sæsonmønsteret.

```
jernbanedata %>%
  features(log(x1000_passagerer), unitroot_nsdiffs) %>%
  kbl(caption = "Anbefalet antal sæsondifferentieringer (D)",
      digits = 0, booktabs = TRUE)
```

```
jernbanedata %>%
  features(log(x1000_passagerer), unitroot_ndiffs) %>%
  kbl(caption = "Anbefalet antal ordinære differentieringer (d)",
      digits = 0, booktabs = TRUE)
```

Tabel 15: Anbefalet antal sæsondifferentieringer (D)

Tabel 16: Anbefalet antal sæsondifferentieringer (D)

key	nsdiffs
International trafik i alt	0
Over Storebælt	0

Tabel 17: Anbefalet antal ordinære differentieringer (d)

Tabel 18: Anbefalet antal ordinære differentieringer (d)

key	ndiffs
International trafik i alt	0
Over Storebælt	0

```
jernbanedata %>%
  mutate(sdiffl_log = difference(log(x1000_passagerer), lag = 4)) %>%
  features(sdiffl_log, unitroot_ndiffs) %>%
  kbl(caption = "Anbefalet d efter sæsondifferentiering (D=1)",
      digits = 0, booktabs = TRUE)
```

KPSS testen kan ikke afvise stationaritetshypotesen ($P > 0,10$) for nogen serie på log skala. trods synlig opadgående trend, afvises den ikke som ikke stationær. Dette skyldes coronaperiodens dyk og efterfølgende genopretning der skaber et mean reversionmønster. Konsistent returnerer nsdiffs og ndiffs begge 0, inkl. corona, og Auto-ARIMA vælger ARIMA(1,0,0)(1,0,0)[4] og ARIMA(1,0,0)(0,0,1)[4] uden differentiering. På det coronarensede datasæt, hvor trendstrukturen er renere, vælger Auto-ARIMA $D = 1$ for begge serier.


```
jernbanedata %>%
  filter(key == "International trafik i alt") %>%
  as_tibble() %>%
  transmute(
    kvartal,
    `log(passagerer)` = log(x1000_passagerer),
    `Δlog (d=1)` = difference(log(x1000_passagerer), 1),
    `Δ log (D=1, lag=4)` = difference(log(x1000_passagerer), 4),
    `ΔΔ log (d=1, D=1)` = difference(difference(log(x1000_passagerer), 4), 1)
  ) %>%
  pivot_longer(~kvartal, names_to = "Type", values_to = "Værdi") %>%
  mutate(Type = factor(Type, levels = c(
    "log(passagerer)", "Δlog (d=1)", "Δ log (D=1, lag=4)", "ΔΔ log (d=1, D=1)"
  ))) %>%
  ggplot(aes(x = kvartal, y = Værdi)) +
  geom_line() +
  facet_grid(vars(Type), scales = "free_y") +
```

Tabel 19: Anbefalet d efter sæsondifferentiering (D=1)

Tabel 20: Anbefalet d efter sæsondifferentiering (D=1)

key	ndiffs
International trafik i alt	0
Over Storebælt	0

```
labs(title = "Differentieringstrin - International trafik i alt",
      y = NULL, x = NULL)
```




Figur 15: Differentieringstrin – International trafik i alt

```
jernbanedata %>%
  filter(key == "International trafik i alt") %>%
  gg_tsdisplay(difference(log(x1000_passagerer), lag = 4),
               plot_type = "partial", lag_max = 24) +
  labs(title = "ACF/PACF - sæsondiff (D=1, lag=4) - International")
```

Warning: Removed 4 rows containing missing values or values outside the scale range (``geom_line()``).

Warning: Removed 4 rows containing missing values or values outside the scale range (``geom_point()``).




Figur 16: ACF/PACF – sæsondiff (D=1, lag=4) – International

```
jernbanedata %>%
  filter(key == "Over Storebælt") %>%
  gg_tsdisplay(difference(log(x1000_passagerer), lag = 4),
    plot_type = "partial", lag_max = 24) +
  labs(title = "ACF/PACF – sæsondiff (D=1, lag=4) – Over Storebælt")
```

Warning: Removed 4 rows containing missing values or values outside the scale range (``geom_line()``).

Warning: Removed 4 rows containing missing values or values outside the scale range (``geom_point()``).



Figur 17: ACF/PACF – sæsondiff (D=1, lag=4) – Over Storebælt


Dobbelt differentiering udelades, da `unitroot_ndiffs` returnerer $d=0$ efter $D=1$. Overdifferentiering forværrer modellen, og derfor anvendes kun $D=1$.

6 STL-dekomposition

```
# STL inkl. corona
stl_comp <- jernbanedata %>%
  model(
    STL(log(x1000_passagerer) ~ trend(window = 7) + season(window = "periodic"),
        robust = TRUE)
  ) %>%
  components()


# STL uden corona
stl_comp_corona <- jernbanedata_corona %>%
  model(
    STL(log(x1000_passagerer) ~ trend(window = 7) + season(window = "periodic"),
        robust = TRUE)
  ) %>%
  components()

stl_comp %>%
  as_tsibble() %>%
  autoplot(`log(x1000_passagerer)`, color = 'gray') +
  geom_line(aes(y = season_adjust), colour = '#0072B2')
```



Figur 18: Sæsonjusteret serie – inkl. corona

```
stl_comp_corona %>%
  as_tsibble() %>%
  autoplot(`log(x1000_passagerer)`, color = 'gray') +
  geom_line(aes(y = season_adjust), colour = '#0072B2')
```




Figur 19: Sæsonjusteret serie – uden corona

```

stl_comp %>%
  autoplot() +
  scale_color_discrete(labels = c("International trafik i alt", "Over Storebælt")) +
  labs(title = "STL-dekomposition - inkl. corona (log-skala)",
        color = "Serie")

```



Figur 20: STL-dekomposition – inkl. corona (log-skala)


```

stl_comp_corona %>%
  autoplot() +
  scale_color_discrete(labels = c("International trafik i alt", "Over Storebælt")) +
  labs(title = "STL-dekomposition - uden corona (log-skala)",
        color = "Serie")

```

STL-dekomposition – uden corona (log-skala)

'log(x1000_passagerer)' = trend + season_year + remainder



Figur 21: STL-dekomposition – uden corona (log-skala)


STL dekompositioner identificerer trend, sæson og remainder for begge serier. Trendkomponenten viser stabil vækst i international trafik frem til 2019 med et markant dyk i 2020 (corona). Over storebælt har en mere jævn trend med mindre udsving. Sæsonkomponenten er periodisk og stabil for begge serier, hvilket er særlig tydeligt for international trafik. Remainder komponenten afslører coronaperioden som et klart ikke sæsonalt strukturbrud, som er mest markant i 2020 Q2 og understøtter konstruktion af det interpolerede datasæt.

```
# Augment - inkl. corona
model_jernbane <- jernbanedata %>%
  model(
    STL = STL(log(x1000_passagerer) ~ trend(window = 7) + season(window = "periodic"),
      robust = TRUE)
  ) %>%
  augment()

# Augment - uden corona
model_jernbane_corona <- jernbanedata_corona %>%
  model(
    STL = STL(log(x1000_passagerer) ~ trend(window = 7) + season(window = "periodic"),
      robust = TRUE)
  ) %>%
  augment()

model_jernbane %>%
  autoplot()
```


Plot variable not specified, automatically selected `.`vars = x1000_passagerer`



Figur 22: Fittede værdier og residualer (STL) – inkl. corona

```
model_jernbane_corona %>%
  autoplot()
```

Plot variable not specified, automatically selected ``vars = x1000_passagerer``



Figur 23: Fittede værdier og residualer (STL) – uden corona

Guerrero estimerer lambda ved at minimere variationskoefficienten på tværs af sæsoner. Et lambda tæt på 0 bekræfter, at log er det rette valg, mens et lambda tæt på 1 betyder, at ingen transformation er nødvendig.

7 Modellering

7.1 Træningssplit

Data deles i en træningsperiode (til og med 2024 Q4) og en testperiode (fra 2025 Q1 og frem) for både datasættet inkl. og uden corona.

```
# Træningsdata: 2006 Q1 til 2024 Q4
jernbane_train <- jernbanedata %>%
  filter_index(. ~ "2024 Q4")

# Testdata: 2025 Q1 til slutningen
jernbane_test <- jernbanedata %>%
  filter_index("2025 Q1" ~ .)

jernbane_corona_train <- jernbanedata_corona %>%
  filter_index(. ~ "2024 Q4")

jernbane_corona_test <- jernbanedata_corona %>%
  filter_index("2025 Q1" ~ .)
```

7.2 Benchmark (SNAIVE)

Der opbygges en benchmark med `stretch_tsibble()`, som udvider træningsvinduet skridt for skridt. SNAIVE anvendes som referencemodel.

```
jernbanestretch <- jernbanedata %>%
  stretch_tsibble(.init = 32, .step = 1)

jernbanestretch_corona <- jernbanedata_corona %>%
  stretch_tsibble(.init = 32, .step = 1)

jernbanestretch %>%
  model(SNAIVE(log(x1000_passagerer))) %>%
  forecast(h = 4) %>%
  accuracy(jernbanedata)
```

Warning: The future dataset is incomplete, incomplete out-of-sample data will be treated as missing.
4 observations are missing between 2026 Q2 and 2027 Q1

```
# A tibble: 2 x 11
  .model          key .type    ME  RMSE  MAE    MPE  MAPE  MASE  RMSSE  ACF1
<chr>          <chr> <chr> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 SNAIVE(log(x1000~ Inte~ Test   5.73  934.  538. -16.9  35.0  1.28  1.21  0.761
2 SNAIVE(log(x1000~ Over~ Test   1.35  362.  239. -4.03  16.6  1.39  1.24  0.543
```

```
jernbanestretch_corona %>%
  model(SNAIVE(log(x1000_passagerer))) %>%
  forecast(h = 4) %>%
  accuracy(jernbanedata_corona)
```

Warning: The future dataset is incomplete, incomplete out-of-sample data will be treated as missing.
4 observations are missing between 2026 Q2 and 2027 Q1

```
# A tibble: 2 x 11
  .model          key .type    ME  RMSE  MAE    MPE  MAPE  MASE  RMSSE  ACF1
<chr>          <chr> <chr> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 SNAIVE(log(x1000~ Inte~ Test  119.  261.  193.  2.85  5.12  1.01  1.03  0.236
2 SNAIVE(log(x1000~ Over~ Test   19.1  129.  101.  0.632  4.77  1.22  1.19  0.596
```

Tabel 21: ETS-modelsammenligning inkl. corona (AICc)

Tabel 22: ETS-modelsammenligning inkl. corona (AICc)

key	.model	sigma2	log_lik	AIC	AICc	BIC	MSE	AMSE	MAE
Over Storebælt	Auto	0,02	-20,24	54,48	56,13	70,80	0,02	0,03	0,08
Over Storebælt	AAA	0,03	-20,50	58,99	61,72	79,97	0,02	0,03	0,08
Over Storebælt	AAAdA	0,03	-20,30	60,59	63,98	83,90	0,02	0,03	0,08
Over Storebælt	MAM	0,00	-23,05	64,10	66,83	85,08	0,02	0,03	0,01
International trafik i alt	Auto	0,05	-48,03	110,06	111,71	126,38	0,05	0,08	0,10
International trafik i alt	AAA	0,05	-47,93	113,86	116,58	134,83	0,05	0,08	0,10
International trafik i alt	AAAdA	0,05	-47,95	115,91	119,29	139,22	0,05	0,08	0,10
International trafik i alt	MAM	0,00	-52,87	123,73	126,46	144,71	0,05	0,09	0,01

7.3 ETS-modeller

Der estimeres flere ETS-specifikationer: en automatisk valgt model samt udvalgte additive og multiplikative varianter.

```
fit_ets <- jernbane_train %>%
  model(
    Auto = ETS(log(x1000_passagerer)),
    AAA = ETS(log(x1000_passagerer) ~ error("A") + trend("A") + season("A")),
    AAAdA = ETS(log(x1000_passagerer) ~ error("A") + trend("Ad") + season("A")),
    MAM = ETS(log(x1000_passagerer) ~ error("M") + trend("A") + season("M"))
  )
```

```
fit_ets_corona <- jernbane_corona_train %>%
  model(
    Auto = ETS(log(x1000_passagerer)),
    AAA = ETS(log(x1000_passagerer) ~ error("A") + trend("A") + season("A")),
    AAAdA = ETS(log(x1000_passagerer) ~ error("A") + trend("Ad") + season("A")),
    MAM = ETS(log(x1000_passagerer) ~ error("M") + trend("A") + season("M"))
  )
```

```
glance(fit_ets) %>%
  arrange(AICc) %>%
  kbl(caption = "ETS-modelsammenligning inkl. corona (AICc)", digits = 2,
      booktabs = TRUE)
```

```
glance(fit_ets_corona) %>%
  arrange(AICc) %>%
  kbl(caption = "ETS-modelsammenligning uden corona (AICc)", digits = 2,
      booktabs = TRUE)
```

7.3.1 Residualanalyse – ETS

Auto ETS opnår laveste AICc for begge serier i begge datasæt. Inkl. corona 112,1 (international) og 56,1 (Storebælt), med de manuelle varianter liggende 5-14 enheder højere, og uden corona -105,1 og -155,9, markant lavere. Dette afspejler reduceret modelusikkerhed. AICc værdier er kun sammenlignelige for samme datasæt


```
fit_ets %>%
  filter(key == "International trafik i alt") %>%
  select(Auto) %>%
  gg_tsresiduals(lag_max = 16)
```

Tabel 23: ETS-modelsammenligning uden corona (AICc)

Tabel 24: ETS-modelsammenligning uden corona (AICc)


key	.model	sigma2	log_lik	AIC	AICc	BIC	MSE	AMSE	MAE
Over Storebælt	Auto	0	85,96	-157,93	-156,28	-141,61	0	0	0,03
Over Storebælt	AAA	0	86,08	-154,15	-151,42	-133,18	0	0	0,03
Over Storebælt	MAM	0	85,81	-153,61	-150,89	-132,64	0	0	0,00
Over Storebælt	AAdA	0	85,95	-151,90	-148,52	-128,60	0	0	0,03
International trafik i alt	Auto	0	64,34	-108,69	-105,30	-85,38	0	0	0,00
International trafik i alt	AAdA	0	63,08	-106,16	-102,78	-82,85	0	0	0,04
International trafik i alt	MAM	0	58,43	-98,86	-96,13	-77,89	0	0	0,00
International trafik i alt	AAA	0	57,79	-97,57	-94,85	-76,60	0	0	0,04

Warning: `gg\_tsresiduals()` was deprecated in feasts 0.4.2.
 i Please use `ggtime::gg\_tsresiduals()` instead.




Figur 24: Residualer – Auto ETS – International (inkl. corona)

```
fit_ets %>%
  filter(key == "Over Storebælt") %>%
  select(Auto) %>%
  gg_tsresiduals(lag_max = 16)
```




Figur 25: Residualer – Auto ETS – Over Storebælt (inkl. corona)

```
fit_ets_corona %>%
  filter(key == "International trafik i alt") %>%
  select(Auto) %>%
  gg_tsresiduals(lag_max = 16)
```



Figur 26: Residualer – Auto ETS – International (uden corona)

```
fit_ets_corona %>%
  filter(key == "Over Storebælt") %>%
  select(Auto) %>%
  gg_tsresiduals(lag_max = 16)
```



Figur 27: Residualer – Auto ETS – Over Storebælt (uden corona)

Ljung-Box-testen anvendes til at teste, om residualerne er ukorreleerede. Lag sættes til 8 (svarende til $2 \times M$ ved kvartalsdata).

```
# Ljung-Box - inkl. corona
augment(fit_ets) %>%
  filter(.model == "Auto", key == "International trafik i alt") %>%
  features(.innov, ljung_box, lag = 8, dof = 0)
```

```
# A tibble: 1 x 4
  key          .model lb_stat lb_pvalue
<chr>         <chr>   <dbl>   <dbl>
1 International trafik i alt Auto      17.2    0.0284
```

```
augment(fit_ets) %>%
  filter(.model == "Auto", key == "Over Storebælt") %>%
  features(.innov, ljung_box, lag = 8, dof = 0)
```

```
# A tibble: 1 x 4
  key          .model lb_stat lb_pvalue
<chr>         <chr>   <dbl>   <dbl>
1 Over Storebælt Auto      23.8    0.00244
```

```
# Ljung-Box - uden corona
augment(fit_ets_corona) %>%
  filter(.model == "Auto", key == "International trafik i alt") %>%
  features(.innov, ljung_box, lag = 8, dof = 0)
```

```
# A tibble: 1 x 4
```

```

  key                .model lb_stat lb_pvalue
  <chr>              <chr>   <dbl>   <dbl>
1 International trafik i alt Auto      23.0  0.00338

augment(fit_ets_corona) %>%
  filter(.model == "Auto", key == "Over Storebælt") %>%
  features(.innov, ljung_box, lag = 8, dof = 0) # Altid .innov for at tjekke

# A tibble: 1 x 4
  key                .model lb_stat lb_pvalue
  <chr>              <chr>   <dbl>   <dbl>
1 Over Storebælt Auto      9.34    0.315

```

Ljung-Box testen afslører en svaghed i auto ETS. inkl. corona forkastes H_0 for begge serier (international: $lb = 17,2$, $p=0,028$) hvilket indikerer ukorrelerede residualer og ej komplet modellering af coronadynamikken. Uden corona forbedres billedet. Storebælt passerer testen, ($lb=9,3$ & $p=0,315$), mens international trafik fortsat fejler ($lb=23,0$ & $p=0,003$). Dette er sandsynligvis grundet kompleks dynamik i international rejseadfærd ud over coronaforstyrrelsen.

7.4 ARIMA-modeller

Der estimeres en automatisk valgt ARIMA samt fire manuelt specificerede SARIMA-modeller, herunder den klassiske airline-model.

```

fit_arima <- jernbane_train %>%
  model(
    Auto = ARIMA(log(x1000_passagerer)),
    # Klassisk "airline model" - MA(1) ordinær + sæsonel
    M1 = ARIMA(log(x1000_passagerer) ~ 0 + pdq(0,1,1) + PDQ(0,1,1)),
    # AR(1) ordinær + sæsonel AR(1)
    M2 = ARIMA(log(x1000_passagerer) ~ 0 + pdq(1,1,0) + PDQ(1,1,0)),
    # Blandet ARMA + sæsonel MA(1)
    M3 = ARIMA(log(x1000_passagerer) ~ 0 + pdq(1,1,1) + PDQ(0,1,1)),
    # AR(2) + sæsonel MA(1)
    M4 = ARIMA(log(x1000_passagerer) ~ 0 + pdq(2,1,0) + PDQ(0,1,1))
  )

fit_arima_corona <- jernbane_corona_train %>%
  model(
    Auto = ARIMA(log(x1000_passagerer)),
    M1 = ARIMA(log(x1000_passagerer) ~ 0 + pdq(0,1,1) + PDQ(0,1,1)),
    M2 = ARIMA(log(x1000_passagerer) ~ 0 + pdq(1,1,0) + PDQ(1,1,0)),
    M3 = ARIMA(log(x1000_passagerer) ~ 0 + pdq(1,1,1) + PDQ(0,1,1)),
    M4 = ARIMA(log(x1000_passagerer) ~ 0 + pdq(2,1,0) + PDQ(0,1,1))
  )

```

Det faktiske antal estimerede parametre fra Auto-modellen hentes og anvendes som frihedsgrader (dof) i Ljung-Box-testen.

```

dof_int <- fit_arima %>%
  filter(key == "International trafik i alt") %>%
  select(Auto) %>%
  coefficients() %>%
  nrow()

dof_osb <- fit_arima %>%
  filter(key == "Over Storebælt") %>%
  select(Auto) %>%

```

Tabel 25: ARIMA-modelsammenligning inkl. corona (AICc)

Tabel 26: ARIMA-modelsammenligning inkl. corona (AICc)

key	.model	sigma2	log_lik	AIC	AICc	BIC
International trafik i alt	Auto	0,06	1,58	4,85	5,41	14,17
International trafik i alt	M1	0,05	0,01	5,97	6,33	12,76
International trafik i alt	M4	0,05	0,13	7,75	8,36	16,80
International trafik i alt	M3	0,05	0,02	7,96	8,57	17,01
International trafik i alt	M2	0,09	-12,89	31,78	32,13	38,56
Over Storebælt	Auto	0,02	34,16	-60,33	-59,77	-51,01
Over Storebælt	M4	0,02	28,90	-49,79	-49,19	-40,74
Over Storebælt	M1	0,02	25,68	-45,35	-45,00	-38,57
Over Storebælt	M3	0,03	25,68	-43,37	-42,76	-34,32
Over Storebælt	M2	0,04	13,47	-20,94	-20,58	-14,15

```

coefficients() %>%
nrow()

dof_corona_int <- fit_arima_corona %>%
  filter(key == "International trafik i alt") %>%
  select(Auto) %>%
  coefficients() %>%
  nrow()

dof_corona_osb <- fit_arima_corona %>%
  filter(key == "Over Storebælt") %>%
  select(Auto) %>%
  coefficients() %>%
  nrow()

cat("International inkl. corona: dof =", dof_int, "\n")

International inkl. corona: dof = 3

cat("Over Storebælt inkl. corona: dof =", dof_osb, "\n")

Over Storebælt inkl. corona: dof = 3

cat("International uden corona: dof =", dof_corona_int, "\n")

International uden corona: dof = 2

cat("Over Storebælt uden corona: dof =", dof_corona_osb, "\n")

Over Storebælt uden corona: dof = 3

glance(fit_arima) %>%
  select(key, .model, sigma2, log_lik, AIC, AICc, BIC) %>%
  arrange(key, AICc) %>%
  kbl(caption = "ARIMA-modelsammenligning inkl. corona (AICc)", digits = 2,
      booktabs = TRUE)

glance(fit_arima_corona) %>%
  select(key, .model, sigma2, log_lik, AIC, AICc, BIC) %>%
  arrange(key, AICc) %>%
  kbl(caption = "ARIMA-modelsammenligning uden corona (AICc)", digits = 2,

```


Tabel 27: ARIMA-modelsammenligning uden corona (AICc)

Tabel 28: ARIMA-modelsammenligning uden corona (AICc)


key	.model	sigma2	log_lik	AIC	AICc	BIC
International trafik i alt	M4	0	109,59	-211,17	-210,57	-202,12
International trafik i alt	Auto	0	106,93	-207,87	-207,51	-201,04
International trafik i alt	M3	0	103,94	-199,87	-199,27	-190,82
International trafik i alt	M1	0	102,17	-198,33	-197,97	-191,54
International trafik i alt	M2	0	99,12	-192,24	-191,88	-185,45
Over Storebælt	Auto	0	135,66	-263,32	-262,73	-254,22
Over Storebælt	M3	0	130,23	-252,46	-251,85	-243,41
Over Storebælt	M1	0	128,83	-251,66	-251,30	-244,87
Over Storebælt	M4	0	128,74	-249,48	-248,87	-240,43
Over Storebælt	M2	0	124,99	-243,99	-243,63	-237,20

```
booktabs = TRUE)
```

Inkl. corona vælger auto ARIMA: ARIMA(1,0,0)(1,0,0)[4] for international trafik (AICc = 5,41), og ARIMA(1,0,0)(0,0,1)[4] for storebælt (AICc = -59,8). Begge stationære ($d=D=0$), som er konsistent med stationaritetstestene. For international trafik indikerer $\phi = 0,734$ (autoregressiv koefficient) stærk AR persistens & $\Phi = 0,299$ moderat sæsonel persistens. For storebælt estimeres $\phi = 0,518$ & $\Theta = 0,306$. Auto udkonkurrer alle de manuelle kandidater på inkl. coronadata. airline-modellen M1 = ARIMA(0,1,1)(0,1,1)[4] scorer AICc = 6,33 — marginalt over Auto men er analytisk velbegrundet. Uden corona vælger auto ARIMA: ARIMA(0,0,1)(0,1,0)[4] med drift (international) og ARIMA(1,0,0)(0,1,2)[4] (Storebælt). Begge med $D=1$, konsistent med en tydeligere sæsontrend.


7.4.1 Residualanalyse – ARIMA

```
fit_arima %>%
  filter(key == "International trafik i alt") %>%
  select(Auto) %>%
  gg_tsresiduals(lag_max = 16) +
  labs(title = "Residualer - Auto ARIMA - International (inkl. corona)")
```




Figur 28: Residualer – Auto ARIMA – International (inkl. corona)

```
fit_arima %>%
  filter(key == "Over Storebælt") %>%
  select(Auto) %>%
  gg_tsresiduals(lag_max = 16) +
  labs(title = "Residualer – Auto ARIMA – Over Storebælt (inkl. corona)")
```




Figur 29: Residualer – Auto ARIMA – Over Storebælt (inkl. corona)

```
fit_arima_corona %>%
  filter(key == "International trafik i alt") %>%
  select(Auto) %>%
  gg_tsresiduals(lag_max = 16) +
  labs(title = "Residualer - Auto ARIMA - International (uden corona)")
```



Figur 30: Residualer - Auto ARIMA - International (uden corona)

```
fit_arima_corona %>%
  filter(key == "Over Storebælt") %>%
  select(Auto) %>%
  gg_tsresiduals(lag_max = 16) +
  labs(title = "Residualer - Auto ARIMA - Over Storebælt (uden corona)")
```



Figur 31: Residualer – Auto ARIMA – Over Storebælt (uden corona)

Residualerne testes for autokorrelation. Nulhypotesen er, at residualerne er ukorrelerede. Lag sættes til 8 ($2 \times M$ ved kvartalsdata), og dof svarer til antallet af estimerede ARMA-parametre i Auto-modellen.

```
# Ljung-Box - inkl. corona
augment(fit_arima) %>%
  filter(.model == "Auto", key == "International trafik i alt") %>%
  features(.innov, ljung_box, lag = 8, dof = dof_int)
```

```
# A tibble: 1 x 4
  key          .model lb_stat lb_pvalue
<chr>         <chr>   <dbl>   <dbl>
1 International trafik i alt Auto      12.6    0.0273
```

```
augment(fit_arima) %>%
  filter(.model == "Auto", key == "Over Storebælt") %>%
  features(.innov, ljung_box, lag = 8, dof = dof_osb)
```

```
# A tibble: 1 x 4
  key          .model lb_stat lb_pvalue
<chr>         <chr>   <dbl>   <dbl>
1 Over Storebælt Auto      11.0    0.0521
```

```
# Ljung-Box - uden corona
augment(fit_arima_corona) %>%
  filter(.model == "Auto", key == "International trafik i alt") %>%
  features(.innov, ljung_box, lag = 8, dof = dof_corona_int)
```

```
# A tibble: 1 x 4
  key          .model lb_stat lb_pvalue
<chr>         <chr>   <dbl>   <dbl>
1 International trafik i alt Auto      17.0    0.00931
```

```
augment(fit_arima_corona) %>%
  filter(.model == "Auto", key == "Over Storebælt") %>%
```

```
features(.innov, ljung_box, lag = 8, dof = dof_corona_osb)
```

```
# A tibble: 1 x 4
  key          .model lb_stat lb_pvalue
  <chr>        <chr>   <dbl>   <dbl>
1 Over Storebælt Auto      5.12     0.401
```

ARIMA residualerne er delvist bedre end ETS. For storebælt er residualerne marginalt ikke signifikante inkl. corona (lb=11,0 & p=0,052) og klart white noise uden corona (lb=5,1 & p=0,401). For international trafik forkastes H_0 , i begge datasæt (p = 0,027 inkl.; p = 0,009 ekskl. corona), da det er identisk med ETS resultatet. Dette indikerer en dynamik som ikke indfanges af hverken ETS eller ARIMA. sandsynligvis relateret til coronaforløbet og efterfølgende genopretningsdynamikker. Forecasts for international trafik bør derfor tolkes med ekstra forsigtighed og brede prædiktionsintervaller.

7.4.2 Optimal ARIMA-søgning

Ved at sætte `stepwise = FALSE` søges alle kombinationer (ikke kun stepwise-stien), og `approximation = FALSE` giver eksakt likelihood og dermed mere præcise AIC/BIC. `order_constraint` begrænser søgerummet, så beregningen ikke tager for lang tid. AICc sammenligner modeller på fit justeret for kompleksitet — lavere AICc er bedre.

```
fit_arma_optimal <- jernbane_train %>%
  model(
    Auto = ARIMA(log(x1000_passagerer)),
    Optimal = ARIMA(
      log(x1000_passagerer),
      stepwise = FALSE,
      approximation = FALSE,
      order_constraint = p + q + P + Q <= 9 & (constant + d + D <= 2)
    )
  )

fit_arma_optimal_corona <- jernbane_corona_train %>%
  model(
    Auto = ARIMA(log(x1000_passagerer)),
    Optimal = ARIMA(
      log(x1000_passagerer),
      stepwise = FALSE,
      approximation = FALSE,
      order_constraint = p + q + P + Q <= 9 & (constant + d + D <= 2)
    )
  )
```

```
glance(fit_arma_optimal) %>%
  arrange(key, AICc) %>%
  kbl(caption = "Optimal ARIMA vs. Auto - inkl. corona (AICc)", digits = 2,
      booktabs = TRUE)
```

```
glance(fit_arma_optimal_corona) %>%
  arrange(key, AICc) %>%
  kbl(caption = "Optimal ARIMA vs. Auto - uden corona (AICc)", digits = 2,
      booktabs = TRUE)
```

Den exhaustive søgning forbedrer AICc i alle tilfælde. Inkl. Corona: International trafik fra 5,41 til -4,75 (-10,2 enheder) & Storebælt fra -59,8 til -75,1 (-15,3 enheder). Uden Corona er forbedringen for international trafik mere beskedent (-207,5 til -216,5), mens storebælt er nærmest identisk (ca -262,7), hvilket indikerer at auto allerede finder det globale optimum. Resultaterne bekræfter at stepwise søgning ikke altid er tilstrækkeligt på komplekse datasæt med corona forstyrrelser.

Tabel 29: Optimal ARIMA vs. Auto – inkl. corona (AICc)

Tabel 30: Optimal ARIMA vs. Auto – inkl. corona (AICc)

key	.model	sigma2	log_lik	AIC	AICc	BIC	ar_roots
International trafik i alt	Optimal	0,05	11,45	-6,90	-4,75	11,74	0,002189361+1,1942610i, 0,002189361-1,1942610i
International trafik i alt	Auto	0,06	1,58	4,85	5,41	14,17	-1,731849e-17+1,352203e+00i, -1,352203e-17-1,352203e+00i
Over Storebælt	Optimal	0,02	45,38	-76,77	-75,12	-60,45	-7,819512e-17+1,293178e+00i, -1,293178e-17-1,293178e+00i
Over Storebælt	Auto	0,02	34,16	-60,33	-59,77	-51,01	1,92951+0i

Tabel 31: Optimal ARIMA vs. Auto – uden corona (AICc)

Tabel 32: Optimal ARIMA vs. Auto – uden corona (AICc)

key	.model	sigma2	log_lik	AIC	AICc	BIC	ar_roots
International trafik i alt	Optimal	0	118,70	-219,41	-216,50	-198,92	0,3021412+1,0081091i, -1,0081091-1,0081091i
International trafik i alt	Auto	0	106,93	-207,87	-207,51	-201,04	
Over Storebælt	Optimal	0	138,16	-264,31	-263,02	-250,65	0,4728045+1,018657e+00i, -1,018657e-17-1,018657e+00i
Over Storebælt	Auto	0	135,66	-263,32	-262,73	-254,22	1,459954+0i

8 Modelsammenligning

`accuracy()` beregner fejlmål (RMSE, MAE, MAPE, MASE) på både trænings- og testdata. Træningsfejlen viser in-sample fit, mens testfejlen viser out-of-sample prædiktionssevne.

```
resultat <- bind_rows(
  fit_arima      %>% accuracy() %>% mutate(data = "Inkl. corona", familie = "ARIMA"),
  fit_ets        %>% accuracy() %>% mutate(data = "Inkl. corona", familie = "ETS"),
  fit_arima_corona %>% accuracy() %>% mutate(data = "Uden corona", familie = "ARIMA"),
  fit_ets_corona  %>% accuracy() %>% mutate(data = "Uden corona", familie = "ETS"),
  fit_arima      %>% forecast(h = 4) %>% accuracy(jernbane_test) %>% mutate(data = "Inkl. corona", familie = "ARIMA"),
  fit_ets        %>% forecast(h = 4) %>% accuracy(jernbane_test) %>% mutate(data = "Inkl. corona", familie = "ETS"),
  fit_arima_corona %>% forecast(h = 4) %>% accuracy(jernbane_corona_test) %>% mutate(data = "Uden corona", familie = "ARIMA"),
  fit_ets_corona  %>% forecast(h = 4) %>% accuracy(jernbane_corona_test) %>% mutate(data = "Uden corona", familie = "ETS")
)

cols <- c("familie", ".model", "key", ".type", "RMSE", "MAE", "MAPE", "MASE")
```

Tabellerne A-H viser fejlmål opdelt på modeltype, datasæt og split. En MASE under 1 betyder, at modellen slår SNAIVE-benchmarken, hvilket er minimumskravet for en brugbar model.

```
resultat %>%
  filter(data == "Inkl. corona", familie == "ARIMA", .type == "Training") %>%
  select(all_of(cols)) %>%
  arrange(key, RMSE) %>%
  kbl(caption = "Tabel A: ARIMA inkl. corona - træning", digits = 2,
      booktabs = TRUE)
```

```
resultat %>%
  filter(data == "Inkl. corona", familie == "ARIMA", .type == "Test") %>%
  select(all_of(cols)) %>%
  arrange(key, RMSE) %>%
  kbl(caption = "Tabel B: ARIMA inkl. corona - test", digits = 2,
      booktabs = TRUE)
```

Tabel 33: Tabel A: ARIMA inkl. corona – træning

Tabel 34: Tabel A: ARIMA inkl. corona – træning

familie	.model	key	.type	RMSE	MAE	MAPE	MASE
ARIMA	M1	International trafik i alt	Training	351,82	176,49	10,43	0,41
ARIMA	M3	International trafik i alt	Training	351,93	176,46	10,42	0,41
ARIMA	M4	International trafik i alt	Training	353,52	177,16	10,47	0,41
ARIMA	Auto	International trafik i alt	Training	438,68	329,08	16,04	0,76
ARIMA	M2	International trafik i alt	Training	612,19	287,71	13,80	0,66
ARIMA	M4	Over Storebælt	Training	199,33	111,28	7,29	0,64
ARIMA	M3	Over Storebælt	Training	203,27	114,75	7,64	0,66
ARIMA	M1	Over Storebælt	Training	203,34	114,62	7,63	0,66
ARIMA	Auto	Over Storebælt	Training	207,72	137,92	9,11	0,79
ARIMA	M2	Over Storebælt	Training	276,47	147,66	9,33	0,85

Tabel 35: Tabel B: ARIMA inkl. corona – test

Tabel 36: Tabel B: ARIMA inkl. corona – test

familie	.model	key	.type	RMSE	MAE	MAPE	MASE
ARIMA	M4	International trafik i alt	Test	259,28	232,06	5,16	NaN
ARIMA	M1	International trafik i alt	Test	263,14	232,27	5,15	NaN
ARIMA	M3	International trafik i alt	Test	265,04	234,60	5,21	NaN
ARIMA	M2	International trafik i alt	Test	570,28	515,36	11,03	NaN
ARIMA	Auto	International trafik i alt	Test	883,00	775,59	16,10	NaN
ARIMA	M2	Over Storebælt	Test	69,55	61,24	2,49	NaN
ARIMA	M4	Over Storebælt	Test	166,17	144,28	5,89	NaN
ARIMA	M3	Over Storebælt	Test	176,34	159,72	6,56	NaN
ARIMA	M1	Over Storebælt	Test	176,85	160,27	6,58	NaN
ARIMA	Auto	Over Storebælt	Test	304,46	266,47	10,69	NaN

Tabel 37: Tabel C: ETS inkl. corona – træning

Tabel 38: Tabel C: ETS inkl. corona – træning

familie	.model	key	.type	RMSE	MAE	MAPE	MASE
ETS	Auto	International trafik i alt	Training	363,49	214,41	11,63	0,49
ETS	AAA	International trafik i alt	Training	371,91	221,52	11,86	0,51
ETS	AAdA	International trafik i alt	Training	374,80	220,18	11,74	0,51
ETS	MAM	International trafik i alt	Training	402,41	243,99	12,74	0,56
ETS	Auto	Over Storebælt	Training	208,10	129,83	8,35	0,75
ETS	AAdA	Over Storebælt	Training	209,21	131,15	8,43	0,76
ETS	MAM	Over Storebælt	Training	210,31	130,11	8,45	0,75
ETS	AAA	Over Storebælt	Training	211,27	136,53	8,68	0,79

Tabel 39: Tabel D: ETS inkl. corona – test

Tabel 40: Tabel D: ETS inkl. corona – test

familie	.model	key	.type	RMSE	MAE	MAPE	MASE
ETS	Auto	International trafik i alt	Test	215,82	168,88	3,71	NaN
ETS	AAdA	International trafik i alt	Test	245,17	214,03	4,78	NaN
ETS	AAA	International trafik i alt	Test	264,72	237,28	5,25	NaN
ETS	MAM	International trafik i alt	Test	619,63	483,12	10,42	NaN
ETS	MAM	Over Storebælt	Test	144,39	120,47	4,96	NaN
ETS	AAA	Over Storebælt	Test	175,91	149,09	6,11	NaN
ETS	AAdA	Over Storebælt	Test	181,48	164,22	6,73	NaN
ETS	Auto	Over Storebælt	Test	190,24	175,26	7,19	NaN

```

resultat %>%
  filter(data == "Inkl. corona", familie == "ETS", .type == "Training") %>%
  select(all_of(cols)) %>%
  arrange(key, RMSE) %>%
  kbl(caption = "Tabel C: ETS inkl. corona - træning", digits = 2,
      booktabs = TRUE)

```

```

resultat %>%
  filter(data == "Inkl. corona", familie == "ETS", .type == "Test") %>%
  select(all_of(cols)) %>%
  arrange(key, RMSE) %>%
  kbl(caption = "Tabel D: ETS inkl. corona - test", digits = 2,
      booktabs = TRUE)

```

```

resultat %>%
  filter(data == "Uden corona", familie == "ARIMA", .type == "Training") %>%
  select(all_of(cols)) %>%
  arrange(key, RMSE) %>%
  kbl(caption = "Tabel E: ARIMA uden corona - træning", digits = 2,
      booktabs = TRUE)

```

```

resultat %>%
  filter(data == "Uden corona", familie == "ARIMA", .type == "Test") %>%
  select(all_of(cols)) %>%
  arrange(key, RMSE) %>%

```


Tabel 41: Tabel E: ARIMA uden corona – træning

Tabel 42: Tabel E: ARIMA uden corona – træning

familie	.model	key	.type	RMSE	MAE	MAPE	MASE
ARIMA	M4	International trafik i alt	Training	175,12	121,63	3,60	0,65
ARIMA	Auto	International trafik i alt	Training	179,98	121,58	3,74	0,65
ARIMA	M3	International trafik i alt	Training	193,75	130,34	3,82	0,70
ARIMA	M1	International trafik i alt	Training	202,11	136,12	3,97	0,73
ARIMA	M2	International trafik i alt	Training	209,69	134,57	3,92	0,72
ARIMA	Auto	Over Storebælt	Training	73,23	55,04	2,65	0,71
ARIMA	M3	Over Storebælt	Training	74,92	51,68	2,50	0,66
ARIMA	M1	Over Storebælt	Training	78,09	55,07	2,65	0,71
ARIMA	M4	Over Storebælt	Training	78,31	56,16	2,71	0,72
ARIMA	M2	Over Storebælt	Training	82,83	58,07	2,80	0,74

Tabel 43: Tabel F: ARIMA uden corona – test

Tabel 44: Tabel F: ARIMA uden corona – test

familie	.model	key	.type	RMSE	MAE	MAPE	MASE
ARIMA	M3	International trafik i alt	Test	94,73	80,57	1,75	NaN
ARIMA	Auto	International trafik i alt	Test	96,02	83,37	1,84	NaN
ARIMA	M1	International trafik i alt	Test	98,12	84,07	1,84	NaN
ARIMA	M4	International trafik i alt	Test	98,63	84,50	1,98	NaN
ARIMA	M2	International trafik i alt	Test	116,48	81,36	1,76	NaN
ARIMA	M2	Over Storebælt	Test	121,27	104,85	4,25	NaN
ARIMA	M4	Over Storebælt	Test	123,52	105,78	4,26	NaN
ARIMA	M1	Over Storebælt	Test	125,92	108,45	4,36	NaN
ARIMA	Auto	Over Storebælt	Test	166,42	146,77	5,89	NaN
ARIMA	M3	Over Storebælt	Test	184,00	167,30	6,76	NaN

```
kbl(caption = "Tabel F: ARIMA uden corona - test", digits = 2,
    booktabs = TRUE)
```

```
resultat %>%
  filter(data == "Uden corona", familie == "ETS", .type == "Training") %>%
  select(all_of(cols)) %>%
  arrange(key, RMSE) %>%
  kbl(caption = "Tabel G: ETS uden corona - træning", digits = 2,
      booktabs = TRUE)
```

```
resultat %>%
  filter(data == "Uden corona", familie == "ETS", .type == "Test") %>%
  select(all_of(cols)) %>%
  arrange(key, RMSE) %>%
  kbl(caption = "Tabel H: ETS uden corona - test", digits = 2,
      booktabs = TRUE)
```

`slice_min/slice_max` finder den model med lavest og højest RMSE pr. gruppe og giver et hurtigt overblik over, hvilke modeller der konsekvent præsterer bedst.

```
opsummering <- resultat %>%
  group_by(data, familie, .type, key) %>%
```

Tabel 45: Tabel G: ETS uden corona – træning

Tabel 46: Tabel G: ETS uden corona – træning

familie	.model	key	.type	RMSE	MAE	MAPE	MASE
ETS	Auto	International trafik i alt	Training	178,14	119,24	3,51	0,64
ETS	AAdA	International trafik i alt	Training	180,05	119,59	3,50	0,64
ETS	MAM	International trafik i alt	Training	188,33	136,07	4,04	0,73
ETS	AAA	International trafik i alt	Training	188,81	136,30	4,06	0,73
ETS	AAA	Over Storebælt	Training	76,60	57,61	2,78	0,74
ETS	Auto	Over Storebælt	Training	76,61	57,64	2,77	0,74
ETS	AAdA	Over Storebælt	Training	76,77	58,79	2,83	0,75
ETS	MAM	Over Storebælt	Training	76,78	57,87	2,79	0,74

Tabel 47: Tabel H: ETS uden corona – test

Tabel 48: Tabel H: ETS uden corona – test

familie	.model	key	.type	RMSE	MAE	MAPE	MASE
ETS	MAM	International trafik i alt	Test	188,23	157,46	3,81	NaN
ETS	Auto	International trafik i alt	Test	204,11	180,41	4,20	NaN
ETS	AAA	International trafik i alt	Test	204,55	173,91	4,18	NaN
ETS	AAdA	International trafik i alt	Test	206,42	179,10	4,02	NaN
ETS	AAA	Over Storebælt	Test	160,92	142,03	5,72	NaN
ETS	MAM	Over Storebælt	Test	161,33	142,79	5,75	NaN
ETS	Auto	Over Storebælt	Test	174,49	156,03	6,29	NaN
ETS	AAdA	Over Storebælt	Test	177,16	158,08	6,37	NaN

Tabel 49: Opsummering: Bedste og dårligste model per gruppe

Tabel 50: Opsummering: Bedste og dårligste model per gruppe

data	familie	.type	key	Bedst_model	Bedst_RMSE	Bedst_MAPE	Dårligst
Inkl. corona	ARIMA	Test	International trafik i alt	M4	259,28	5,16	Auto
Inkl. corona	ARIMA	Test	Over Storebælt	M2	69,55	2,49	Auto
Inkl. corona	ARIMA	Training	International trafik i alt	M1	351,82	10,43	M2
Inkl. corona	ARIMA	Training	Over Storebælt	M4	199,33	7,29	M2
Inkl. corona	ETS	Test	International trafik i alt	Auto	215,82	3,71	MAM
Inkl. corona	ETS	Test	Over Storebælt	MAM	144,39	4,96	Auto
Inkl. corona	ETS	Training	International trafik i alt	Auto	363,49	11,63	MAM
Inkl. corona	ETS	Training	Over Storebælt	Auto	208,10	8,35	AAA
Uden corona	ARIMA	Test	International trafik i alt	M3	94,73	1,75	M2
Uden corona	ARIMA	Test	Over Storebælt	M2	121,27	4,25	M3
Uden corona	ARIMA	Training	International trafik i alt	M4	175,12	3,60	M2
Uden corona	ARIMA	Training	Over Storebælt	Auto	73,23	2,65	M2
Uden corona	ETS	Test	International trafik i alt	MAM	188,23	3,81	AAAdA
Uden corona	ETS	Test	Over Storebælt	AAA	160,92	5,72	AAAdA
Uden corona	ETS	Training	International trafik i alt	Auto	178,14	3,51	AAA
Uden corona	ETS	Training	Over Storebælt	AAA	76,60	2,78	MAM

```

summarise(
  Bedst_model      = .model[which.min(RMSE)],
  Bedst_RMSE       = min(RMSE),
  Bedst_MAPE       = MAPE[which.min(RMSE)],
  Dårligst_model   = .model[which.max(RMSE)],
  Dårligst_RMSE    = max(RMSE),
  Dårligst_MAPE    = MAPE[which.max(RMSE)],
  .groups = "drop"
) %>%
  arrange(data, familie, .type, key)

opsummering %>%
  kbl(caption = "Opsummering: Bedste og dårligste model per gruppe", digits = 2,
      booktabs = TRUE)

```

8.1 Time series cross validation

TSCV udvider træningsvinduerne skridt for skridt og forecaster fire kvartaler frem ($H=4$). Dette giver et mere robust estimat af prognosefejlen end et enkelt train/test-split. SNAIVE bruges som benchmark; en god model bør have lavere RMSE end SNAIVE.

```

# Time series cross validation med corona
resultat_tscv <- jernbanestretch %>%
  model(
    ARIMA = ARIMA(log(x1000_passagerer)),
    ETS    = ETS(log(x1000_passagerer)),
    SNAIVE = SNAIVE(log(x1000_passagerer))
  ) %>%
  forecast(h = 4) %>%
  accuracy(jernbanedata) %>%
  mutate(data = "Inkl. corona")

```

Tabel 51: TSCV-modelsammenligning inkl. og uden corona

Tabel 52: TSCV-modelsammenligning inkl. og uden corona

data	.model	key	RMSE	MAE	MAPE	MASE
Inkl. corona	ETS	International trafik i alt	762,13	437,99	26,86	1,04
Inkl. corona	ARIMA	International trafik i alt	845,17	546,56	29,78	1,30
Inkl. corona	SNAIVE	International trafik i alt	933,53	538,10	34,99	1,28
Inkl. corona	SNAIVE	Over Storebælt	362,19	238,85	16,61	1,39
Inkl. corona	ETS	Over Storebælt	408,14	243,75	16,67	1,41
Inkl. corona	ARIMA	Over Storebælt	408,76	267,94	17,57	1,55
Uden corona	SNAIVE	International trafik i alt	261,18	193,00	5,12	1,01
Uden corona	ARIMA	International trafik i alt	263,78	191,95	5,16	1,01
Uden corona	ETS	International trafik i alt	276,16	197,95	5,22	1,04
Uden corona	ETS	Over Storebælt	120,26	94,27	4,44	1,14
Uden corona	SNAIVE	Over Storebælt	129,40	101,38	4,77	1,22
Uden corona	ARIMA	Over Storebælt	130,90	105,15	4,93	1,27

Warning: The future dataset is incomplete, incomplete out-of-sample data will be treated as missing.
4 observations are missing between 2026 Q2 and 2027 Q1

```
# Time series cross validation uden corona
resultat_tscv_corona <- jernbanestretch_corona %>%
  model(
    ARIMA = ARIMA(log(x1000_passagerer)),
    ETS = ETS(log(x1000_passagerer)),
    SNAIVE = SNAIVE(log(x1000_passagerer))
  ) %>%
  forecast(h = 4) %>%
  accuracy(jernbanedata_corona) %>%
  mutate(data = "Uden corona")
```

Warning: The future dataset is incomplete, incomplete out-of-sample data will be treated as missing.
4 observations are missing between 2026 Q2 and 2027 Q1

```
bind_rows(resultat_tscv, resultat_tscv_corona) %>%
  select(data, .model, key, RMSE, MAE, MAPE, MASE) %>%
  arrange(data, key, RMSE) %>%
  kbl(caption = "TSCV-modelsammenligning inkl. og uden corona", digits = 2,
      booktabs = TRUE)
```

TSCV er den metodisk mest robuste evaluering. En central begrænsning er at ingen model opnår MASE < 1 på nogen kombination, Det er altså ikke alle modeller der slår SNAIVE benchmark modellen. Inkl. corona dominerer COVID kvartalerne fejlestimerne: RMSE på 762–934 (international) og 362–409 (Storebælt), MASE på 1,04–1,55. Uden corona er fejlene markant lavere, og MASE tættest på 1. ARIMA og SNAIVE er næsten identiske for international trafik (MASE=1,01) mens ETS marginalt er bedst for storebælt (RMSE = 120, MASE = 1,14). At MASE fortsat overstiger 1 skyldes sandsynligvis, at det stærke og konsistente sæsonmønster netop favoriserer SNAIVE. Corona perioden forringer evalueringsgrundlaget inkl. corona kraftigt, det interpolerede datasæt giver et mere retvisende billede af modellernes relative præstation.

RMSE pr. forecast-horisont viser, om prognosefejlen stiger markant med horisonten. SNAIVE inkluderes som reference for at vurdere, om modellerne tilfører værdi over tid.

```
# Med corona
actuals <- jernbanedata %>%
  as_tibble() %>%
```


```

select(kvartal, key, actual = x1000_passagerer)

# Uden corona
actuals_corona <- jernbanedata_corona %>%
  as_tibble() %>%
  select(kvartal, key, actual = x1000_passagerer)


jernbanestretch %>%
  model(
    ARIMA = ARIMA(log(x1000_passagerer)),
    ETS = ETS(log(x1000_passagerer)),
    SNAIVE = SNAIVE(log(x1000_passagerer))
  ) %>%
  forecast(h = 4) %>%
  as_tibble() %>%
  group_by(.id, key, .model) %>%
  mutate(h = row_number()) %>%
  ungroup() %>%
  left_join(actuals, by = c("kvartal", "key")) %>%
  group_by(.model, key, h) %>%
  summarise(RMSE = sqrt(mean((.mean - actual)^2, na.rm = TRUE)),
    .groups = "drop") %>%
  ggplot(aes(x = h, y = RMSE, colour = .model)) +
  geom_line() +
  geom_point() +
  facet_wrap(~ key, scales = "free_y") +
  scale_x_continuous(breaks = 1:4, labels = c("Q+1", "Q+2", "Q+3", "Q+4")) +
  labs(title = "RMSE per forecast-horisont (h=1-4)",
    x = "Horisont", y = "RMSE", colour = "Model") +
  theme_minimal()

```



Figur 32: RMSE per forecast-horisont (h=1-4) – inkl. corona

```
jernbanestretch_corona %>%
  model(
    ARIMA = ARIMA(log(x1000_passagerer)),
    ETS = ETS(log(x1000_passagerer)),
    SNAIVE = SNAIVE(log(x1000_passagerer))
  ) %>%
  forecast(h = 4) %>%
  as_tibble() %>%
  group_by(.id, key, .model) %>%
  mutate(h = row_number()) %>%
  ungroup() %>%
  left_join(actuals_corona, by = c("kvartal", "key")) %>%
  group_by(.model, key, h) %>%
  summarise(RMSE = sqrt(mean((.mean - actual)^2, na.rm = TRUE)), .groups = "drop") %>%
  ggplot(aes(x = h, y = RMSE, colour = .model)) +
  geom_line() + geom_point() +
  facet_wrap(~ key, scales = "free_y") +
  scale_x_continuous(breaks = 1:4, labels = c("Q+1", "Q+2", "Q+3", "Q+4")) +
  labs(title = "RMSE per forecast-horisont - uden corona",
       x = "Horisont", y = "RMSE", colour = "Model") +
  theme_minimal()
```



Figur 33: RMSE per forecast-horisont (h=1–4) – uden corona

9 Forecasting og prædiktion

`hilo()` beregner prædiktionsintervaller på 80 % og 95 %; et bredere interval betyder større usikkerhed. `unpack_hilo()` adskiller intervallerne i separate lower/upper-kolonner til tabelvisning.

```
jernbanedata %>%
  model(
    ARIMA = ARIMA(log(x1000_passagerer)),
    ETS = ETS(log(x1000_passagerer))
```

Tabel 53: Forecast og prædiktionsintervaller inkl. corona (80% og 95%)

\begin{table}
\caption{Forecast og prædiktionsintervaller inkl. corona (80% og 95%)}

key	.model	kvartal	.mean	80%_lower	80%_upper	95%_lower	95%_upper
International trafik i alt	ARIMA	2026 Q2	4273,9	3081,8	5615,3	2629,3	6581,8
International trafik i alt	ARIMA	2026 Q3	4266,5	2815,4	5948,1	2309,7	7250,3
International trafik i alt	ARIMA	2026 Q4	3900,1	2464,5	5587,5	1984,5	6939,1
International trafik i alt	ARIMA	2027 Q1	3720,5	2298,3	5404,6	1832,7	6777,4
International trafik i alt	ETS	2026 Q2	4755,7	3510,6	6145,7	3027,0	7127,5
International trafik i alt	ETS	2026 Q3	5664,3	3742,3	7890,8	3071,7	9613,4
International trafik i alt	ETS	2026 Q4	4979,0	3001,4	7339,3	2368,9	9299,0
International trafik i alt	ETS	2027 Q1	4412,8	2453,8	6812,0	1872,7	8925,7
Over Storebælt	ARIMA	2026 Q2	2284,0	1858,8	2743,0	1676,9	3040,5
Over Storebælt	ARIMA	2026 Q3	2232,8	1780,8	2724,1	1591,3	3048,5
Over Storebælt	ARIMA	2026 Q4	2239,1	1766,6	2754,5	1570,7	3098,2
Over Storebælt	ARIMA	2027 Q1	2134,1	1673,8	2637,2	1484,0	2974,5
Over Storebælt	ETS	2026 Q2	2390,8	1946,0	2870,8	1755,7	3182,0
Over Storebælt	ETS	2026 Q3	2490,3	1959,9	3069,4	1740,5	3456,4
Over Storebælt	ETS	2026 Q4	2579,3	1969,8	3251,8	1725,0	3713,2
Over Storebælt	ETS	2027 Q1	2273,0	1688,7	2923,9	1460,3	3381,2

\end{table}

```
) %>%
forecast(h = 4) %>%
hilo(level = c(80, 95)) %>%
unpack_hilo(c("80%", "95%")) %>%
select(key, .model, kvartal, .mean,
       `80%_lower`, `80%_upper`,
       `95%_lower`, `95%_upper`) %>%
kbl(caption = "Forecast og prædiktionsintervaller inkl. corona (80% og 95%)",
     digits = 1, booktabs = TRUE)
```

```
jernbanedata_corona %>%
model(
  ARIMA = ARIMA(log(x1000_passagerer)),
  ETS = ETS(log(x1000_passagerer))
) %>%
forecast(h = 4) %>%
hilo(level = c(80, 95)) %>%
unpack_hilo(c("80%", "95%")) %>%
select(key, .model, kvartal, .mean,
       `80%_lower`, `80%_upper`,
       `95%_lower`, `95%_upper`) %>%
kbl(caption = "Forecast og prædiktionsintervaller uden corona (80% og 95%)",
     digits = 1, booktabs = TRUE)
```

`filter_index` afskærer historikken, så prædiktionsintervallerne er visuelt tydelige. Begge modeller vises i samme plot til direkte sammenligning af forecast og usikkerhed.

```
jernbanedata %>%
model(
  ARIMA = ARIMA(log(x1000_passagerer)),
```

Tabel 54: Forecast og prædiktionsintervaller uden corona (80% og 95%)

\begin{table}
\caption{Forecast og prædiktionsintervaller uden corona (80% og 95%)}


key	.model	kvartal	.mean	80%_lower	80%_upper	95%_lower	95%_upper
International trafik i alt	ARIMA	2026 Q2	5034,0	4688,0	5389,6	4518,1	5592,3
International trafik i alt	ARIMA	2026 Q3	5561,9	5062,1	6080,1	4822,4	6382,2
International trafik i alt	ARIMA	2026 Q4	4626,4	4210,6	5057,4	4011,2	5308,7
International trafik i alt	ARIMA	2027 Q1	4310,4	3923,0	4711,9	3737,2	4946,1
International trafik i alt	ETS	2026 Q2	4750,0	4421,5	5087,6	4260,3	5280,1
International trafik i alt	ETS	2026 Q3	5221,7	4838,0	5616,7	4650,7	5843,0
International trafik i alt	ETS	2026 Q4	4556,6	4205,2	4919,0	4034,3	5127,4
International trafik i alt	ETS	2027 Q1	4193,2	3849,6	4548,2	3683,4	4753,4
Over Storebælt	ARIMA	2026 Q2	2356,1	2243,8	2470,6	2187,3	2534,4
Over Storebælt	ARIMA	2026 Q3	2291,8	2158,6	2428,0	2092,5	2504,8
Over Storebælt	ARIMA	2026 Q4	2453,7	2300,2	2611,1	2224,3	2700,2
Over Storebælt	ARIMA	2027 Q1	2170,6	2030,2	2314,6	1961,0	2396,3
Over Storebælt	ETS	2026 Q2	2397,3	2275,8	2521,2	2215,0	2590,4
Over Storebælt	ETS	2026 Q3	2297,0	2161,4	2435,8	2094,1	2514,1
Over Storebælt	ETS	2026 Q4	2445,2	2283,1	2611,7	2203,2	2706,3
Over Storebælt	ETS	2027 Q1	2226,4	2046,1	2412,7	1958,7	2520,2

\end{table}

```

ETS = ETS(log(x1000_passagerer))
) |>
forecast(h = 4) %>%
autoplot(jernbanedata %>% filter_index("2020 Q1" ~ .),
         level = c(80, 95)) +
facet_wrap(~ key, scales = "free_y") +
labs(title = "Forecast med prædiktionsintervaller (80% og 95%)",
     y = "1.000 passagerer", x = NULL) +
theme_minimal()

```

Figur 34: Forecast med prædiktionsintervaller (80% og 95%)

Forecasts er baseret på modeller estimeret på det fulde datasæt (2006Q1-2026Q1) med en horisont på fire kvartaler til 2027Q1. Log transformationen medfører assymetriske prædiktionsintervaller på originalskalaen (log normal fordeling) hvor opadrettede intervaller er bredere end nedadrettede. Intervallerne udvides med horisonten i takt med akkumuleret usikkerhed.

ARIMA & ETS er enige om retningen for begge serier, fortsat positiv vækst for international trafik i forlængelse af genopretningstrenden fra 2022 og mere stabil, moderat vækst for storeblælt konsistent med lavere trendstyrke. For international trafik er 80% & 95% prædiktionsintervallerne brede, konsistent med den højere modelusikkerhed afspejlet i ljung-box resultaterne.

10 Sammenfatning og konklusion

Nedenfor kombineres STL-styrker, COVID-behandling og bedste model i ét overblik pr. serie. Det gør det nemt at sammenligne på tværs af de to datasæt og de to tidsrækker.

```
stl_features <- bind_rows(
  jernbanedata %>% features(x1000_passagerer, feat_stl) %>% mutate(data = "Inkl. corona"),
  jernbanedata_corona %>% features(x1000_passagerer, feat_stl) %>% mutate(data = "Uden corona")
) %>%
  select(key, data, trend_strength, seasonal_strength_year)
```

`slice_min` finder den model med lavest test-RMSE pr. serie og datasæt.

```
bedste <- resultat %>%
  filter(.type == "Test") %>%
  group_by(data, key) %>%
  slice_min(RMSE, n = 1) %>%
  select(key, data, Bedste_model = .model, MASE, RMSE)
```

```
sammenfatning <- stl_features %>%
  left_join(bedste, by = c("key", "data")) %>%
  mutate(
```

Tabel 55: Sammenfatningsoversigt: Nøgletal per serie og datasæt

Tabel 56: Sammenfatningsoversigt: Nøgletal per serie og datasæt

Serie	Datasæt	Trend	Sæson	COVID	Bedste_model	RMSE
International trafik i alt	Inkl. corona	0,965	0,813	Ja – ubehandlet	Auto	215,823
International trafik i alt	Uden corona	0,962	0,856	Interpoleret	M3	94,731
Over Storebælt	Inkl. corona	0,866	0,513	Ja – ubehandlet	M2	69,555
Over Storebælt	Uden corona	0,908	0,800	Interpoleret	M2	121,271

```

COVID_impact = case_when(
  data == "Inkl. corona" ~ "Ja - ubehandlet",
  data == "Uden corona" ~ "Interpoleret"
)
) %>%
select(
  Serie      = key,
  Datasæt    = data,
  Trend      = trend_strength,
  Sæson      = seasonal_strength_year,
  COVID      = COVID_impact,
  Bedste_model,
  RMSE
) %>%
arrange(Serie, Datasæt)

sammenfatning %>%
  kbl(caption = "Sammenfatningsoversigt: Nøgletal per serie og datasæt",
      digits = 3, booktabs = TRUE)

```

10.1 Sammenfatning & Konklusion

Seriekarakteristika: Begge serier har stærke trendkomponenter (0,87-0,97). International trafik har den stærkeste sæsonstruktur (0,86 uden corona). Storebælt er mere afdæmpet sæsonstruktur (0,80) som forstyrres uforholdsmæssigt af corona. Guerrero analysen ($\lambda = 0$ på coronafri data) understøtter log transformation gennemgående.

Stationaritet: Coronaperioden svækker stationaritetsvurderingen. KPSS afviser ikke stationaritet inkl. corona, og auto ARIMA vælger $d=D=0$. Det interpolerede datasæt giver et mere korrekt grundlag, hvor $D=1$ vælges konsistent med den underliggende sæsontrend.

Modelpræstation: ETS opnår den laveste AICc & TSCV RMSE for international trafik inkl. corona (762) mod ARIMA (845). For storebælt uden corona (RMSE=120, MASE=1,14). Den exhaustive ARIMA søgning forbedrer AICc betydeligt, særligt for international trafik inkl. corona (5,4 til -4,8)

Residualanalyse: International trafik udviser vedvarende autokorrelerede residualer i begge modelklasser, og datasæt (Ljung-Box $p < 0,05$), hvilket antyder en dynamik uden for ARIMA/ETS rammens rækkevidde. Storebælt uden corona er den eneste kombination, hvor begge modeltypers residualtests består testen.

Benchmark og begrænsninger: Ingen af modellerne opnår $MASE < 1$ i TSCV, ingen slår SNAIVE. Inkl corona skyldes dette corona kvartaler som historiske mønstre ikke kan forudsige. Uden corona er MASE tæt på, men over 1. Corona interpolationen er analysens primære metodologiske forbehold, da interpolerede observationer er et skøn, og resultater på det rensede datasæt skal tolkes derefter.