

Jernbanetransport af passagerer i Danmark

Mathias Andersen, Nicklas Helmundt & Nikolaj Aaby Larsen

2026-06-17

Indholdsfortegnelse

1	Indledning	1
2	Data og dataforberedelse	1
3	Eksplorativ dataanalyse	1
3.1	Tidsserieplot	1
3.2	Sæsonplot	2
3.3	ACF og PACF	4
3.4	Deskriptive statistikker	10
3.5	STL-features: trend- og sæsonstyrke	10
4	Transformation	10
4.1	Box-Cox og Guerrero	10
5	Stationaritet og differentiering	13
6	STL-dekomposition	16
7	Modellering	19
7.1	Træningssplit	19
7.2	Benchmark (SNAIVE)	19
7.3	ETS-modeller	20
7.3.1	Residualanalyse – ETS	20
7.4	ARIMA-modeller	24
7.4.1	Residualanalyse – ARIMA	26
7.4.2	Optimal ARIMA-søgning	28
8	Modelsammenligning	29
8.1	Time series cross validation	31
9	Forecasting og prædiktion	33
10	Sammenfatning og konklusion	35

Figuroversigt

1	Jernbanepassagerer	1
2	Log-transformerede jernbanepassagerer	2
3	Sæsonplot	3
4	Subserie-plot	4
5	ACF + PACF – International trafik i alt (log, inkl. corona)	5
6	ACF + PACF – Over Storebælt (log, inkl. corona)	5
7	ACF + PACF – International trafik i alt (log, uden corona)	6
8	ACF + PACF – Over Storebælt (log, uden corona)	7
9	Lag-plot – Over Storebælt (inkl. corona)	8
10	Lag-plot – International trafik i alt (inkl. corona)	8
11	Lag-plot – Over Storebælt (uden corona)	9
12	Lag-plot – International trafik i alt (uden corona)	10
13	Differentieringstrin – International trafik i alt	15
14	ACF/PACF – sæsondiff (D=1, lag=4) – International	15
15	ACF/PACF – sæsondiff (D=1, lag=4) – Over Storebælt	16
16	Sæsonjusteret serie – inkl. corona	17
17	STL-dekomposition – inkl. corona (log-skala)	18
18	Fittede værdier og residualer (STL) – inkl. corona	19
19	RMSE per forecast-horisont (h=1–4)	33
20	Forecast med prædiktionsintervaller (80% og 95%)	35

Tabeloversigt

1	Deskriptive statistikker	11
2	Deskriptive statistikker – Inkl. corona	11
3	Deskriptive statistikker – Uden corona	11
4	Trend- og sæsonstyrke inkl. corona	12
5	Trend- og sæsonstyrke – Inkl. corona	12
6	Trend- og sæsonstyrke – Uden corona	12
7	Guerrero-optimeret Box-Cox lambda inkl. corona	12
8	Guerrero-optimeret Box-Cox lambda – Inkl. corona	12
9	Guerrero-optimeret Box-Cox lambda – Uden corona	12
10	KPSS-test på log(passagerer) — H0: stationær	13
11	KPSS-test på log(passagerer) — H0: stationær	13
12	Anbefalet antal sæsondifferentieringer (D)	13
13	Anbefalet antal sæsondifferentieringer (D)	13
14	Anbefalet antal ordinære differentieringer (d)	13
15	Anbefalet antal ordinære differentieringer (d)	13
16	Anbefalet d efter sæsondifferentiering (D=1)	14
17	Anbefalet d efter sæsondifferentiering (D=1)	14
18	SNAIVE benchmark – Inkl. corona	20
19	SNAIVE benchmark – Uden corona	20
20	ETS-modelsammenligning inkl. corona (AICc)	21
21	ETS-modelsammenligning uden corona (AICc)	21
22	ARIMA-modelsammenligning inkl. corona (AICc)	25
23	ARIMA-modelsammenligning uden corona (AICc)	26
24	inkl. corona	27
25	inkl. corona	27
26	Uden corona	28
27	Uden corona	28
28	Optimal ARIMA vs. Auto – inkl. corona (AICc)	29
29	Opsummering: Bedste og dårligste model per gruppe	31
30	TSCV-modelsammenligning inkl. og uden corona	32

31	NULL	34
32	Sammenfatningsoversigt: Nøgletal per serie og datasæt	36

1 Indledning

Denne rapport analyserer kvartalsvise passagertal for jernbanetransport i Danmark. Der fokuseres på to serier: international trafik i alt samt trafik over Storebælt. Formålet er at beskrive serierne, vurdere deres sæson- og trendstruktur og dernæst opbygge og sammenligne prognosemodeller (ETS og ARIMA) med og uden coronaperioden.


2 Data og dataforberedelse

Datasættet indlæses fra Danmarks Statistiks tabel BANE25 og Datasættet dækker perioden 2006k1 til og med 2026k1. Indekset er kvartaler, nøglen (**key**) er trafiktype, og responsvariablen er antallet af passagerer i 1.000. Der udvælges to relevante kategorier: international trafik i alt samt trafik over Storebælt.

Der laves også et datasæt uden coronaperioden, da nedlukningerne ikke betragtes som et gentagende fænomen. Her anvendes `forecast::na.interp()` til at udfylde NA-felterne med en lineær interpolation mellem perioden før og efter corona.


3 Eksplorativ dataanalyse

3.1 Tidsserieplot



Figur 1: Jernbanepassagerer

```
kør_begge(function(data, titel) {  
  data %>%  
    autoplot(log(x1000_passagerer)) +  
    labs(title = titel,  
         y = "log(1.000 passagerer)",  
         x = NULL)  
})
```




Figur 2: Log-transformerede jernbanepassagerer

Begge serier viser en opadgående trend fra 2006 til 2019 med et markant dyk under coronaperioden i 2020. Log-transformationen stabiliserer variansen og gør sæsonudslagene mere konstante over tid.

3.2 Sæsonplot


```
kør_begge(function(data, titel) {
  data %>%
    gg_season(x1000_passagerer) +
    labs(title = titel,
         y     = "1.000 passagerer",
         x     = NULL)
})
```



Figur 3: Sæsonplot

Sæsonplottene bekræfter et konsistent Q3 peak på tværs af alle år for international trafik. For Over Storebælt er sæsonudslaget mindre synligt, da forskellen mellem Q1 & Q3 er mindre end for international trafik. I det interpolerede datasæt fremstår alle år med næsten parallelle forløb, hvilket vidner om et homogent sæsonmønster uden strukturbrud.

```
kør_begge(function(data, titel) {
  data %>%
    gg_subseries(x1000_passagerer) +
    labs(title = titel,
         y     = "1.000 passagerer",
         x     = NULL)
})
```




Figur 4: Subserie-plot

Begge serier viser et tydeligt sæsonmønster med toppe i tredje kvartal (Q3) og bund i første kvartal (Q1), samt opadgående trend fra 2006 til 2026 med undtagelse af coronaperioden (2020-2021).


3.3 ACF og PACF

```
jernbanedata %>%
  filter(key == "International trafik i alt") %>%
  mutate(x1000_passagerer = log(x1000_passagerer)) %>%
  gg_tsdisplay(x1000_passagerer, plot_type = "partial", lag_max = 24) +
  labs(title = "ACF + PACF (log, inkl. corona)")
```




Figur 5: ACF + PACF – International trafik i alt (log, inkl. corona)

```
jernbanedata %>%
  filter(key == "Over Storebælt") %>%
  mutate(x1000_passagerer = log(x1000_passagerer)) %>%
  gg_tsdisplay(x1000_passagerer, plot_type = "partial", lag_max = 24) +
  labs(title = "ACF + PACF (log, inkl. corona)")
```




Figur 6: ACF + PACF – Over Storebælt (log, inkl. corona)


```
jernbanedata_corona %>%
  filter(key == "International trafik i alt") %>%
  mutate(x1000_passagerer = log(x1000_passagerer)) %>%
  gg_tsdisplay(x1000_passagerer, plot_type = "partial", lag_max = 24) +
  labs(title = "ACF + PACF (log, uden corona)")
```



Figur 7: ACF + PACF – International trafik i alt (log, uden corona)

```
jernbanedata_corona %>%
  filter(key == "Over Storebælt") %>%
  mutate(x1000_passagerer = log(x1000_passagerer)) %>%
  gg_tsdisplay(x1000_passagerer, plot_type = "partial", lag_max = 24) +
  labs(title = "ACF + PACF (log, uden corona)")
```



Figur 8: ACF + PACF – Over Storebælt (log, uden corona)

ACF Plottene for rådata (Log skala) viser lag som, eksponentiel aftagen uden klart cutoff, som er normalt for ikke stationære serier med trend. Signifikante toppe optræder ved lag 4 & 8. (kvartalsvis sæsonperiode)

PACF-plottene afskæres efter lag 1–2 for den ordinære komponent, hvilket indikerer en AR-struktur. For den sæsonale komponent er PACF signifikant ved lag 4 for international trafik, hvilket peger på en sæsonel AR-komponent.

Samlet begrundet dette kandidatmodeller med $ARIMA(p,d,q)(P,D,Q)[4]$, hvor de konkrete ordener bestemmes via stationaritetstest og AICc-sammenligning.

```
jernbanedata %>%
  filter(key == "Over Storebælt") %>%
  gg_lag(x1000_passagerer, geom = "point") +
  labs(x = "lag(x1000_passagerer, k)")
```




Figure 9: Lag-plot – Over Storebælt (inkl. corona)

```
jernbanedata %>%
  filter(key == "International trafik i alt") %>%
  gg_lag(x1000_passagerer, geom = "point") +
  labs(x = "lag(x1000_passagerer, k)")
```






Figure 10: Lag-plot – International trafik i alt (inkl. corona)

```
jernbanedata_corona %>%
  filter(key == "Over Storebælt") %>%
  gg_lag(x1000_passagerer, geom = "point") +
  labs(x = "lag(x1000_passagerer, k)")
```



Figur 11: Lag-plot – Over Storebælt (uden corona)

```
jernbanedata_corona %>%
  filter(key == "International trafik i alt") %>%
  gg_lag(x1000_passagerer, geom = "point") +
  labs(x = "lag(x1000_passagerer, k)")
```



Figur 12: Lag-plot – International trafik i alt (uden corona)

Lag-plottene viser sammenhængen mellem en observation og dens tidligere værdier. En tydelig lineær sammenhæng ved lag 4 bekræfter det kvartalsvise sæsonmønster i begge serier.

3.4 Deskriptive statistikker

International trafik i alt viser et gennemsnit på 3076 passagerer og en varianskoeficient på 29% (SD=893), med et spænd fra 619 til 5.315 drevet af coronanedgangen. Over storebælt er trafikken væsentlig mere stabil: Gennemsnit 2.019 og varianskoeficient på 15% (SD=301).

Den markant større spredning i International Trafik begrundes anvendelse af en varians stabiliserende transformation, samt opdeling i 2 separate datasæt.

3.5 STL-features: trend- og sæsonstyrke

STL features bekræfter de visuelle observationer kvantitativt. International trafik i alt har høj trend styrke (0,965 & 0,962 inkl/ekskl. corona) og sæsonstyrke (0,813/0,856) hvor coronaperioden kun dæmper sæsonmønsteret minimalt. Over storebælt er effekten mere markant, trend styrken stiger fra 0,866 til 0,908 og sæsonstyrken øges fra 0,513 til 0,800 uden corona. Dette betyder at pandemiens ekstreme udsving indikerer at sæsonkomponenter er nødvendige i både ETS & SARIMA.

4 Transformation

4.1 Box-Cox og Guerrero

Guerrero metoden estimerer inkl. corona en lambda på 0,855 (international) og Lambda 2,00 (storebælt). Disse værdier er dog kunstigt oppustede af coronaperiodens udsving, og er ikke repræsentative for den underliggende varians struktur. Det corona rensede datasæt giver et mere retvisende billede med lambda -0,606 (international) og -0,051 (Storebælt), hvor storebælt er tæt på 0, og dermed understøtter log transformation. Log transformationen fastholdes konsekvent for begge serier i al efterfølgende modellering og fable tilbagekalkulerer automatisk til originalskala ved forecast. Dette understøttes af figur 1 & 2

Tabel 1: Deskriptive statistikker

```
kør_begge_tbl(function(data, titel) {
  data %>%
    as_tibble() %>%
    group_by(key) %>%
    summarise(
      N      = sum(!is.na(x1000_passagerer)),
      mean   = mean(x1000_passagerer,      na.rm = TRUE),
      median = median(x1000_passagerer,     na.rm = TRUE),
      sd     = sd(x1000_passagerer,        na.rm = TRUE),
      Q1     = quantile(x1000_passagerer, 0.25, na.rm = TRUE),
      Q3     = quantile(x1000_passagerer, 0.75, na.rm = TRUE),
      min    = min(x1000_passagerer,       na.rm = TRUE),
      max    = max(x1000_passagerer,      na.rm = TRUE)
    ) %>%
    kbl(caption = paste0("Deskriptive statistikker - ", titel),
        digits = 1, booktabs = TRUE) %>%
    kable_styling(latex_options = c("striped", "hold_position"))
})
```

[!h]

Tabel 2: Deskriptive statistikker – Inkl. corona

key	N	mean	median	sd	Q1	Q3	min	max
International trafik i alt	81	3075,8	3049	892,9	2654	3528	619	5315
Over Storebælt	81	2019,4	2061	300,7	1945	2177	738	2568

[!h]

Tabel 3: Deskriptive statistikker – Uden corona

key	N	mean	median	sd	Q1	Q3	min	max
International trafik i alt	81	3287,9	3237	677,9	2879	3584,2	1696	5315
Over Storebælt	81	2104,4	2108	147,7	2023	2177,0	1820	2568

Tabel 4: Trend- og sæsonstyrke inkl. corona

```
kør_begge_tbl(function(data, titel) {
  data %>%
    features(x1000_passagerer, feat_stl) %>%
    select(trend_strength, seasonal_strength_year) %>%
    kbl(caption = paste0("Trend- og sæsonstyrke - ", titel),
        digits = 3,
        booktabs = TRUE) %>%
    kable_styling(latex_options = c("striped", "hold_position"))
})
```

[!h]

Tabel 5: Trend- og sæsonstyrke – Inkl. corona

trend_strength	seasonal_strength_year
0,965	0,813
0,866	0,513

[!h]

Tabel 6: Trend- og sæsonstyrke – Uden corona

trend_strength	seasonal_strength_year
0,962	0,856
0,908	0,800

Tabel 7: Guerrero-optimeret Box-Cox lambda inkl. corona

```
kør_begge_tbl(function(data, titel) {
  data %>%
    features(x1000_passagerer, features = guerrero) %>%
    rename(Lambda_Guerrero = lambda_guerrero) %>%
    kbl(caption = paste0("Guerrero-optimeret Box-Cox lambda - ", titel),
        digits = 3,
        booktabs = TRUE) %>%
    kable_styling(latex_options = c("striped", "hold_position"))
})
```

[!h]

Tabel 8: Guerrero-optimeret Box-Cox lambda – Inkl. corona

key	Lambda_Guerrero
International trafik i alt	0,855
Over Storebælt	2,000

[!h]

Tabel 9: Guerrero-optimeret Box-Cox lambda – Uden corona

key	Lambda_Guerrero
International trafik i alt	-0,606
Over Storebælt	-0,051

Tabel 10: KPSS-test på $\log(\text{passagerer})$ — H_0 : stationær

[!h]

Tabel 11: KPSS-test på $\log(\text{passagerer})$ — H_0 : stationær

key	kpss_stat	kpss_pvalue
International trafik i alt	0,1865	0,1
Over Storebælt	0,2156	0,1

Tabel 12: Anbefalet antal sæsondifferentieringer (D)

[!h]

Tabel 13: Anbefalet antal sæsondifferentieringer (D)

key	nsdiffs
International trafik i alt	0
Over Storebælt	0

5 Stationaritet og differentiering

```
jernbanedata %>%
  features(log(x1000_passagerer), unitroot_kpss) %>%
  kbl(caption = "KPSS-test på log(passagerer) - H0: stationær",
      digits = 4, booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position"))
```

```
jernbanedata %>%
  features(log(x1000_passagerer), unitroot_nsdiffs) %>%
  kbl(caption = "Anbefalet antal sæsondifferentieringer (D)",
      digits = 0, booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position"))
```

```
jernbanedata %>%
  features(log(x1000_passagerer), unitroot_ndiffs) %>%
  kbl(caption = "Anbefalet antal ordinære differentieringer (d)",
      digits = 0, booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position"))
```

```
jernbanedata %>%
  mutate(sdiff_log = difference(log(x1000_passagerer), lag = 4)) %>%
  features(sdiff_log, unitroot_ndiffs) %>%
  kbl(caption = "Anbefalet d efter sæsondifferentiering (D=1)",
      digits = 0, booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position"))
```

Tabel 14: Anbefalet antal ordinære differentieringer (d)

[!h]

Tabel 15: Anbefalet antal ordinære differentieringer (d)

key	ndiffs
International trafik i alt	0
Over Storebælt	0

Tabel 16: Anbefalet d efter sæsondifferentiering (D=1)


[!h]

Tabel 17: Anbefalet d efter sæsondifferentiering (D=1)

key	ndiffs
International trafik i alt	0
Over Storebælt	0


KPSS testen kan ikke afvise stationaritetens hypotesen ($P > 0,10$) for nogen serie på log skala. trods synlig opadgående trend, afvises den ikke som ikke stationær Dette skyldes coronaperiodens dyk og efterfølgende genopretning der skaber et mean reversionsmønster. Konsistent returnerer nsdiffs og ndiffs begge 0, inkl. corona, og Auto-ARIMA vælger ARIMA(1,0,0)(1,0,0)[4] og ARIMA(1,0,0)(0,0,1)[4] uden differentiering. På det corona-rensede datasæt, hvor trendstrukturen er renere, vælger Auto-ARIMA $D = 1$ for begge serier.

```
jernbanedata %>%
  filter(key == "International trafik i alt") %>%
  as_tibble() %>%
  transmute(
    kvartal,
    `log(passagerer)`      = log(x1000_passagerer),
    `Δlog (d=1)`           = difference(log(x1000_passagerer), 1),
    `Δ log (D=1, lag=4)`   = difference(log(x1000_passagerer), 4),
    `ΔΔ log (d=1, D=1)`   = difference(difference(log(x1000_passagerer), 4), 1)
  ) %>%
  pivot_longer(-kvartal, names_to = "Type", values_to = "Værdi") %>%
  mutate(Type = factor(Type, levels = c(
    "log(passagerer)", "Δlog (d=1)", "Δ log (D=1, lag=4)", "ΔΔ log (d=1, D=1)"
  ))) %>%
  ggplot(aes(x = kvartal, y = Værdi)) +
  geom_line() +
  facet_grid(vars(Type), scales = "free_y") +
  labs(title = "Differentieringstrin - International trafik i alt",
    y = NULL, x = NULL)
```




Figur 13: Differentieringstrin – International trafik i alt

```
jernbanedata %>%
  filter(key == "International trafik i alt") %>%
  gg_tsdisplay(difference(log(x1000_passagerer), lag = 4),
    plot_type = "partial", lag_max = 24) +
  labs(title = "ACF/PACF – sæsondiff (D=1, lag=4) – International")
```



Figur 14: ACF/PACF – sæsondiff (D=1, lag=4) – International

```
jernbanedata %>%
  filter(key == "Over Storebælt") %>%
  gg_tsdisplay(difference(log(x1000_passagerer), lag = 4),
    plot_type = "partial", lag_max = 24) +
  labs(title = "ACF/PACF - sæsondiff (D=1, lag=4) - Over Storebælt")
```




Figur 15: ACF/PACF - sæsondiff (D=1, lag=4) - Over Storebælt

Dobbelt differentiering udelades, da `unitroot_ndiffs` returnerer $d=0$ efter $D=1$. Overdifferentiering forværrer modellen, og derfor anvendes kun $D=1$.

6 STL-dekomposition

```
# STL inkl. corona
stl_comp <- function(data) {
  data %>%
    model(
      STL(log(x1000_passagerer) ~ trend(window = 7) + season(window = "periodic"),
        robust = TRUE)
    ) %>%
    components()
}
```


```
kør_begge(function(data, titel) {
  stl_comp(data) %>%
    as_tsibble() %>%
    autoplot(`log(x1000_passagerer)`, color = "gray") +
    geom_line(aes(y = season_adjust), colour = "#0072B2") +
    labs(title = paste0("Sæsonjusteret serie - ", titel),
      y = "log(1.000 passagerer)",
      x = NULL)
})
```



Figur 16: Sæsonjusteret serie – inkl. corona

Den grå linje viser den rå log-transformerede serie mens den blå linje viser den sæsonjusterede serie. Den underliggende trend fremstår tydeligt efter sæsonkomponenten er fjernet.

```
kør_begge(function(data, titel) {
  stl_comp(data) %>%
    autoplot() +
    scale_color_discrete(labels = c("International trafik i alt", "Over Storebælt")) +
    labs(title = paste0("STL-dekomposition - ", titel),
         color = "Serie",
         x      = NULL)
})
```




Figur 17: STL-dekomposition – inkl. corona (log-skala)

STL dekompositioner identificerer trend, sæson og remainder for begge serier. Trendkomponenten viser stabil vækst i international trafik frem til 2019 med et markant dyk i 2020 (corona). Over storebælt har en mere jævn trend med mindre udsving. Sæsonkomponenten er periodisk og stabil for begge serier, hvilket er særlig tydeligt for international trafik. Remainder komponenten afslører coronaperioden som et klart ikke sæsonalt strukturbud, som er mest markant i 2020 Q2 og understøtter konstruktion af det interpolerede datasæt.

```
model_jernbane <- function(data) {
  data %>%
    model(
      STL = STL(log(x1000_passagerer) ~ trend(window = 7) + season(window = "periodic"),
        robust = TRUE)
    ) %>%
    augment()
}
```

```
kør_begge(function(data, titel) {
  model_jernbane(data) %>%
    autoplot(.resid) +
    labs(title = paste0("Residualer STL - ", titel),
      y = "Residualer",
      x = NULL)
})
```



Figur 18: Fittede værdier og residualer (STL) – inkl. corona

Residualerne er generelt små og centrerede omkring nul, bortset fra coronaperioden i 2020. Det store udsving i 2020 bekræfter at coronaperioden ikke kan forklares af den normale sæson og trendstruktur.

7 Modellering

7.1 Træningssplit

Data deles i en træningsperiode (til og med 2024 Q4) og en testperiode (fra 2025 Q1 og frem) for både datasættet inkl. og uden corona.

```
jernbane_train <- jernbanedata %>%
  filter_index(. ~ "2024 Q4")

jernbane_test <- jernbanedata %>%
  filter_index("2025 Q1" ~ .)

jernbane_corona_train <- jernbanedata_corona %>%
  filter_index(. ~ "2024 Q4")

jernbane_corona_test <- jernbanedata_corona %>%
  filter_index("2025 Q1" ~ .)
```

7.2 Benchmark (SNAIVE)

```
lav_stretch <- function(data) {
  data %>%
    stretch_tsibble(.init = 32, .step = 1)
}
```

```
# SNAIVE benchmark
kør_begge_tbl(function(data, titel) {
```

```

lav_stretch(data) %>%
  model(SNAIVE(log(x1000_passagerer))) %>%
  forecast(h = 3) %>%
  accuracy(data) %>%
  kbl(caption = paste0("SNAIVE benchmark - ", titel),
      digits = 2,
      booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position"))
})

```

Tabel 18: SNAIVE benchmark – Inkl. corona

.model	key	.type	ME	RMSE	MAE	MPE	MAPE	MASE
SNAIVE(log(x1000_passagerer))	International trafik i alt	Test	3,68	929,59	532,93	-16,92	34,73	1,26
SNAIVE(log(x1000_passagerer))	Over Storebælt	Test	0,65	360,41	236,66	-4,03	16,46	1,37

Tabel 19: SNAIVE benchmark – Uden corona

.model	key	.type	ME	RMSE	MAE	MPE	MAPE	MASE
SNAIVE(log(x1000_passagerer))	International trafik i alt	Test	117,16	259,98	191,78	2,80	5,09	1,01
SNAIVE(log(x1000_passagerer))	Over Storebælt	Test	18,52	128,76	100,65	0,61	4,73	1,21

7.3 ETS-modeller

```

lav_ets <- function(data) {
  data %>%
    model(
      Auto = ETS(log(x1000_passagerer)),
      AAA = ETS(log(x1000_passagerer) ~ error("A") + trend("A") + season("A")),
      AAdA = ETS(log(x1000_passagerer) ~ error("A") + trend("Ad") + season("A")),
      MAM = ETS(log(x1000_passagerer) ~ error("M") + trend("A") + season("M"))
    )
}

fit_ets <- lav_ets(jernbane_train)
fit_ets_corona <- lav_ets(jernbane_corona_train)

glance(fit_ets_corona) %>%
  select(key, .model, AIC, AICc) %>%
  arrange(AICc) %>%
  kbl(digits = 2, booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position"))

```

7.3.1 Residualanalyse – ETS

Auto ETS har lavest AICc i alle fire grupper og er dermed den foretrukne model ved begge datasæt: 56,13 og 66,83 inkl. corona, -156,28 og -105,30 uden corona. To forbehold er centrale: AICc kan kun sammenlignes inden for samme serie og datasæt (derfor er -156,28 ikke “bedre” end 56,13), Her måles kun in-sample-tilpasning — ikke forudsigelsesevne. Dette bliver gjort på testfejlene (RMSE)

```

for (serie in c("International trafik i alt", "Over Storebælt")) {
  print(
    fit_ets %>%

```

Tabel 20: ETS-modelsammenligning inkl. corona (AICc)

```
glance(fit_ets) %>%
  select(key, .model, AICc, BIC) %>%
  arrange(AICc) %>%
  kbl(digits = 2, booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position"))
```

[!h]

key	.model	AICc	BIC
Over Storebælt	Auto	56,13	70,80
Over Storebælt	AAA	61,72	79,97
Over Storebælt	AAdA	63,98	83,90
Over Storebælt	MAM	66,83	85,08
International trafik i alt	Auto	111,71	126,38
International trafik i alt	AAA	116,58	134,83
International trafik i alt	AAdA	119,29	139,22
International trafik i alt	MAM	126,46	144,71

Tabel 21: ETS-modelsammenligning uden corona (AICc)






[!h]

key	.model	AIC	AICc
Over Storebælt	Auto	-157,93	-156,28
Over Storebælt	AAA	-154,15	-151,42
Over Storebælt	MAM	-153,61	-150,89
Over Storebælt	AAdA	-151,90	-148,52
International trafik i alt	Auto	-108,69	-105,30
International trafik i alt	AAdA	-106,16	-102,78
International trafik i alt	MAM	-98,86	-96,13
International trafik i alt	AAA	-97,57	-94,85


```

    filter(key == serie) %>%
    select(Auto) %>%
    gg_tsresiduals(lag_max = 16) +
    labs(title = paste0("Residualer - Auto ETS - ", serie))
  ) %>%
  cat("\n\n")
}






```



```

for (serie in c("International trafik i alt", "Over Storebælt")) {
  print(
    fit_ets_corona %>%
    filter(key == serie) %>%
    select(Auto) %>%
    gg_tsresiduals(lag_max = 16) +
    labs(title = paste0("Residualer - Auto ETS - ", serie))
  ) %>%
  cat("\n\n")
}

```



```
for (serie in c("International trafik i alt", "Over Storebælt")) {
  augment(fit_ets) %>%
  filter(.model == "Auto", key == serie) %>%
  features(.innov, ljung_box, lag = 8, dof = 0) %>%
  kbl(caption = paste0("Ljung-Box - Auto ETS - ", serie),
      digits = 2,
      booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position")) %>%
  print()
  cat("\n\n")
}
```

```
\begin{table}[!h]
\centering
\caption{\label{tab:ljung-ets}Ljung-Box - Auto ETS - International trafik i alt}
\centering
\begin{tabular}{t}{llrr}
\toprule
key & .model & lb\_stat & lb\_pvalue\\
\midrule
\cellcolor{gray!10}{International trafik i alt} & \cellcolor{gray!10}{Auto} & \cellcolor{gray!10}{17,16} & \\
\bottomrule
\end{tabular}
\end{table}
```

```
\begin{table}[!h]
\centering
\caption{\label{tab:ljung-ets}Ljung-Box - Auto ETS - Over Storebælt}
\centering
\begin{tabular}{t}{llrr}
\toprule
key & .model & lb\_stat & lb\_pvalue\\
\midrule
```

```

\cellcolor{gray!10}{Over Storebælt} & \cellcolor{gray!10}{Auto} & \cellcolor{gray!10}{23,84} & \cellcol
\bottomrule
\end{tabular}
\end{table}

```

```

# Ljung-Box - uden corona
for (serie in c("International trafik i alt", "Over Storebælt")) {
  augment(fit_ets_corona) %>%
    filter(.model == "Auto", key == serie) %>%
    features(.innov, ljung_box, lag = 8, dof = 0) %>%
    kbl(caption = paste0("Ljung-Box - Auto ETS - ", serie),
        digits = 2,
        booktabs = TRUE) %>%
    kable_styling(latex_options = c("striped", "hold_position")) %>%
    print()
  cat("\n\n")
}

```

```

\begin{table}[!h]
\centering
\caption{\label{tab:ljung-ets}Ljung-Box - Auto ETS - International trafik i alt}
\centering
\begin{tabular}[t]{llrr}
\toprule
key & .model & lb\_stat & lb\_pvalue\\
\midrule
\cellcolor{gray!10}{International trafik i alt} & \cellcolor{gray!10}{Auto} & \cellcolor{gray!10}{22,99} & \\
\bottomrule
\end{tabular}
\end{table}

```

```

\begin{table}[!h]
\centering
\caption{\label{tab:ljung-ets}Ljung-Box - Auto ETS - Over Storebælt}
\centering
\begin{tabular}[t]{llrr}
\toprule
key & .model & lb\_stat & lb\_pvalue\\
\midrule
\cellcolor{gray!10}{Over Storebælt} & \cellcolor{gray!10}{Auto} & \cellcolor{gray!10}{9,34} & \cellcolo
\bottomrule
\end{tabular}
\end{table}

```

Ljung-Box testen afslører en svaghed i auto ETS. inkl. corona forkastes H_0 for begge serier (international: $lb = 17,2$, $p=0,028$) hvilket indikerer ukorrelerede residualer og ej komplet modellering af coronadynamikken. Uden corona forbedres billedet. Storebælt passerer testen, ($lb=9,3$ & $p=0,315$), mens international trafik fortsat fejler ($lb=23,0$ & $p=0,003$). Dette er sandsynligvis grundet kompleks dynamik i international rejseadfærd ud over coronaforstyrrelsen.

7.4 ARIMA-modeller

```

lav_arima <- function(data) {
  data %>%
    model(
      Auto = ARIMA(log(x1000_passagerer)),

```

Tabel 22: ARIMA-modellsammenligning inkl. corona (AICc)

[!h]	key	.model	log_lik	AIC	AICc	BIC
	International trafik i alt	Auto	1,58	4,85	5,41	14,17
	International trafik i alt	M1	0,01	5,97	6,33	12,76
	International trafik i alt	M4	0,13	7,75	8,36	16,80
	International trafik i alt	M3	0,02	7,96	8,57	17,01
	International trafik i alt	M2	-12,89	31,78	32,13	38,56
	Over Storebælt	Auto	34,16	-60,33	-59,77	-51,01
	Over Storebælt	M4	28,90	-49,79	-49,19	-40,74
	Over Storebælt	M1	25,68	-45,35	-45,00	-38,57
	Over Storebælt	M3	25,68	-43,37	-42,76	-34,32
	Over Storebælt	M2	13,47	-20,94	-20,58	-14,15

```

M1 = ARIMA(log(x1000_passagerer) ~ 0 + pdq(0,1,1) + PDQ(0,1,1)),
M2 = ARIMA(log(x1000_passagerer) ~ 0 + pdq(1,1,0) + PDQ(1,1,0)),
M3 = ARIMA(log(x1000_passagerer) ~ 0 + pdq(1,1,1) + PDQ(0,1,1)),
M4 = ARIMA(log(x1000_passagerer) ~ 0 + pdq(2,1,0) + PDQ(0,1,1))
)
}

fit_arma      <- lav_arma(jernbane_train)
fit_arma_corona <- lav_arma(jernbane_corona_train)

hent_dof <- function(fit, serie) {
  fit %>%
    filter(key == serie) %>%
    select(Auto) %>%
    coefficients() %>%
    nrow()
}

dof_int <- hent_dof(fit_arma, "International trafik i alt")
dof_osb <- hent_dof(fit_arma, "Over Storebælt")

dof_int_corona <- hent_dof(fit_arma_corona, "International trafik i alt")
dof_osb_corona <- hent_dof(fit_arma_corona, "Over Storebælt")

glance(fit_arma) %>%
  select(key, .model, log_lik, AIC, AICc, BIC) %>%
  arrange(key, AICc) %>%
  kbl(digits = 2, booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position"))

glance(fit_arma_corona) %>%
  select(key, .model, log_lik, AIC, AICc, BIC) %>%
  arrange(key, AICc) %>%
  kbl(digits = 2, booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position"))

```

Inkl. corona vælger auto ARIMA: ARIMA(1,0,0)(1,0,0)[4] for international trafik (AICc = 5,41), og ARIMA(1,0,0)(0,0,1)[4] for storebælt (AICc = -59,8). Begge stationære ($d=D=0$), som er konsistent med stationaritetstestene. For international trafik indikerer $\phi = 0,734$ (autoregressiv koefficient) stærk AR persistens & $\Phi = 0,299$ moderat sæsonel persistens. For storebælt estimeres $\phi = 0,518$ & $\Theta = 0,306$. Auto udkonkurrer alle de


Tabel 23: ARIMA-modelsammenligning uden corona (AICc)

[!h]	key	.model	log_lik	AIC	AICc	BIC
	International trafik i alt	M4	109,59	-211,17	-210,57	-202,12
	International trafik i alt	Auto	106,93	-207,87	-207,51	-201,04
	International trafik i alt	M3	103,94	-199,87	-199,27	-190,82
	International trafik i alt	M1	102,17	-198,33	-197,97	-191,54
	International trafik i alt	M2	99,12	-192,24	-191,88	-185,45
	Over Storebælt	Auto	135,66	-263,32	-262,73	-254,22
	Over Storebælt	M3	130,23	-252,46	-251,85	-243,41
	Over Storebælt	M1	128,83	-251,66	-251,30	-244,87
	Over Storebælt	M4	128,74	-249,48	-248,87	-240,43
	Over Storebælt	M2	124,99	-243,99	-243,63	-237,20

manuelle kandidater på inkl. coronadata. airline-modellen M1 = ARIMA(0,1,1)(0,1,1)[4] scorer AICc = 6,33 — marginalt over Auto men er analytisk velbegrunderet. Uden corona vælger auto ARIMA: ARIMA(0,0,1)(0,1,0)[4] med drift (international) og ARIMA(1,0,0)(0,1,2)[4] (Storebælt). Begge med D=1, konsistent med en tydeligere sæsontrend.

7.4.1 Residualanalyse – ARIMA


```
for (serie in c("International trafik i alt", "Over Storebælt")) {
  residualer <- fit_arima %>%
    filter(key == serie) %>%
    select(Auto) %>%
    gg_tsresiduals(lag_max = 16) +
    labs(title = paste0("Residualer - Auto ARIMA - ", serie, " - Inkl. corona"))
  print(residualer)
  cat("\n\n")
}
```



```

for (serie in c("International trafik i alt", "Over Storebælt")) {
  residualer <- fit_arima_corona %>%
    filter(key == serie) %>%
    select(Auto) %>%
    gg_tsresiduals(lag_max = 16) +
    labs(title = paste0("Residualer - Auto ARIMA - ", serie, " - Inkl. corona"))
  print(residualer)
  cat("\n\n")
}

```



```

for (serie in c("International trafik i alt", "Over Storebælt")) {
  dof <- hent_dof(fit_arima, serie)
  augment(fit_arima) %>%
    filter(.model == "Auto", key == serie) %>%
    features(.innov, ljung_box, lag = 8, dof = dof) %>%
    kbl(caption = "inkl. corona", digits = 2, booktabs = TRUE) %>%
    kable_styling(latex_options = c("striped", "HOLD_position")) %>%
    print()
  cat("\n\n")
}

```

Tabel 24: inkl. corona

key	.model	lb_stat	lb_pvalue
International trafik i alt	Auto	12,61	0,03

Tabel 25: inkl. corona

key	.model	lb_stat	lb_pvalue
Over Storebælt	Auto	10,96	0,05

```

for (serie in c("International trafik i alt", "Over Storebælt")) {
  dof <- hent_dof(fit_arma_corona, serie)
  augment(fit_arma_corona) %>%
    filter(.model == "Auto", key == serie) %>%
    features(.innov, ljung_box, lag = 8, dof = dof) %>%
    kbl(caption = " Uden corona", digits = 2, booktabs = TRUE) %>%
    kable_styling(latex_options = c("striped", "HOLD_position")) %>%
    print()
  cat("\n\n")
}

```

Tabel 26: Uden corona

key	.model	lb_stat	lb_pvalue
International trafik i alt	Auto	16,99	0,01

Tabel 27: Uden corona

key	.model	lb_stat	lb_pvalue
Over Storebælt	Auto	5,12	0,4

ARIMA residualerne er delvist bedre end ETS. For storebælt er residualerne marginalt ikke signifikante inkl. corona ($lb=11,0$ & $p=0,052$) og klart white noise uden corona ($lb=5,1$ & $p=0,401$). For international trafik forkastes H_0 , i begge datasæt ($p = 0,027$ inkl.; $p = 0,009$ ekskl. corona), da det er identisk med ETS resultatet. Dette indikerer en dynamik som ikke indfanges af hverken ETS eller ARIMA. sandsynligvis relateret til coronaforløbet og efterfølgende genopretningsdynamikker. Forecasts for international trafik bør derfor tolkes med ekstra forsigtighed og brede prædiktionsintervaller.

7.4.2 Optimal ARIMA-søgning

```

lav_arma_optimal <- function(data) {
  data %>%
    model(
      Auto = ARIMA(log(x1000_passagerer)),
      Optimal = ARIMA(
        log(x1000_passagerer),
        stepwise = FALSE,
        approximation = FALSE,
        order_constraint = p + q + P + Q <= 9 & (constant + d + D <= 2)
      )
    )
}

fit_arma_optimal <- lav_arma_optimal(jernbane_train)
fit_arma_optimal_corona <- lav_arma_optimal(jernbane_corona_train)

```

Den exhaustive søgning forbedrer AICc i alle tilfælde. Inkl. Corona: International trafik fra 5,41 til -4,75 (-10,2 enheder) & Storebælt fra -59,8 til -75,1 (-15,3 enheder). Uden Corona er forbedringen for international trafik mere beskedende (-207,5 til -216,5), mens storebælt er nærmest identisk (ca -262,7), hvilket indikerer at auto allerede finder det globale optimum. Resultaterne bekræfter at stepwise søgning ikke altid er tilstrækkeligt på komplekse datasæt med corona forstyrrelser.

Tabel 28: Optimal ARIMA vs. Auto – inkl. corona (AICc)

```
for (fit in list(fit_arma_optimal, fit_arma_optimal_corona)) {
  titel <- if (identical(fit, fit_arma_optimal)) "Inkl. corona" else "Uden corona"
  glance(fit) %>%
    select(key, .model, AIC, AICc) %>%
    arrange(key, AICc) %>%
    kbl(digits = 2, booktabs = TRUE) %>%
    kable_styling(latex_options = c("striped", "hold_position")) %>%
    print()
  cat("\n\n")
}
```

[!h]

key	.model	AIC	AICc
International trafik i alt	Optimal	-6,90	-4,75
International trafik i alt	Auto	4,85	5,41
Over Storebælt	Optimal	-76,77	-75,12
Over Storebælt	Auto	-60,33	-59,77

[!h]

key	.model	AIC	AICc
International trafik i alt	Optimal	-219,41	-216,50
International trafik i alt	Auto	-207,87	-207,51
Over Storebælt	Optimal	-264,31	-263,02
Over Storebælt	Auto	-263,32	-262,73

8 Modelsammenligning

```
resultat <- bind_rows(
  fit_arma %>%
    accuracy() %>%
    mutate(data = "Inkl. corona", familie = "ARIMA"),
  fit_ets %>%
    accuracy() %>%
    mutate(data = "Inkl. corona", familie = "ETS"),
  fit_arma_corona %>%
    accuracy() %>%
    mutate(data = "Uden corona", familie = "ARIMA"),
  fit_ets_corona %>%
    accuracy() %>%
    mutate(data = "Uden corona", familie = "ETS"),

  fit_arma %>%
    forecast(h = 4) %>%
    accuracy(jernbane_test) %>%
    mutate(data = "Inkl. corona", familie = "ARIMA"),
  fit_ets %>%
    forecast(h = 4) %>%
    accuracy(jernbane_test) %>%
    mutate(data = "Inkl. corona", familie = "ETS"),
  fit_arma_corona %>%
    forecast(h = 4) %>%
    accuracy(jernbane_corona_test) %>%
    mutate(data = "Uden corona", familie = "ARIMA"),
```



```

fit_ets_corona %>%
  forecast(h = 4) %>%
  accuracy(jernbane_corona_test) %>%
  mutate(data = "Uden corona", familie = "ETS")
) %>%
  mutate(across(where(is.numeric), ~ round(.x, 2)))

```

Tabellerne A-H viser fejlmål opdelt på modeltype, datasæt og split, hvor en MASE under 1 indikerer, at modellen overgår SNAIVE-benchmarken og dermed er brugbar.

```

kombinationer <- expand_grid(
  data      = c("Inkl. corona", "Uden corona"),
  familie   = c("ARIMA", "ETS"),
  type      = c("Training", "Test"),
  stringsAsFactors = FALSE
)

tabel_labels <- c("A", "B", "C", "D", "E", "F", "G", "H")

cols <- c(".model", "key", ".type", "RMSE")

for (i in seq_len(nrow(kombinationer))) {
  type_val      <- kombinationer$type[i]
  familie_val   <- kombinationer$familie[i]
  data_val      <- kombinationer$data[i]
  label         <- tabel_labels[i]
  type_dk       <- if (type_val == "Training") "træning" else "test"

  resultat %>%
    filter(data == data_val,
           familie == familie_val,
           .type == type_val) %>%
    select(all_of(cols)) %>%
    arrange(key, RMSE) %>%
    kbl(digits = 2, booktabs = TRUE) %>%
    kable_styling(latex_options = c("striped", "hold_position"))
}

```

slice_min/slice_max finder den model med lavest og højest RMSE pr. gruppe og giver et hurtigt overblik over, hvilke modeller der konsekvent præsterer bedst.

```

opsummering <- resultat %>%
  group_by(data, familie, .type, key) %>%
  summarise(
    Bedst_model      = .model[which.min(RMSE)],
    Bedst_RMSE       = min(RMSE),
    Bedst_MAPE        = MAPE[which.min(RMSE)],
    .groups = "drop"
  ) %>%
  arrange(data, .type, familie, key)

opsummering %>%
  kbl(digits = 2, booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position"))

```

Tabel 29: Opsummering: Bedste og dårligste model per gruppe

[!h]

data	familie	.type	key	Bedst_model	Bedst_RMSE	Bedst_MAPE
Inkl. corona	ARIMA	Test	International trafik i alt	M4	259,28	5,16
Inkl. corona	ARIMA	Test	Over Storebælt	M2	69,55	2,49
Inkl. corona	ETS	Test	International trafik i alt	Auto	215,82	3,71
Inkl. corona	ETS	Test	Over Storebælt	MAM	144,39	4,96
Inkl. corona	ARIMA	Training	International trafik i alt	M1	351,82	10,43
Inkl. corona	ARIMA	Training	Over Storebælt	M4	199,33	7,29
Inkl. corona	ETS	Training	International trafik i alt	Auto	363,49	11,63
Inkl. corona	ETS	Training	Over Storebælt	Auto	208,10	8,35
Uden corona	ARIMA	Test	International trafik i alt	M3	94,73	1,75
Uden corona	ARIMA	Test	Over Storebælt	M2	121,27	4,25
Uden corona	ETS	Test	International trafik i alt	MAM	188,23	3,81
Uden corona	ETS	Test	Over Storebælt	AAA	160,92	5,72
Uden corona	ARIMA	Training	International trafik i alt	M4	175,12	3,60
Uden corona	ARIMA	Training	Over Storebælt	Auto	73,23	2,65
Uden corona	ETS	Training	International trafik i alt	Auto	178,14	3,51
Uden corona	ETS	Training	Over Storebælt	AAA	76,60	2,78

8.1 Time series cross validation

```
# Time series cross validation med corona
lav_tscv <- function(stretch, reference, data_label) {
  stretch %>%
    model(
      ARIMA = ARIMA(log(x1000_passagerer)),
      ETS = ETS(log(x1000_passagerer)),
      SNAIVE = SNAIVE(log(x1000_passagerer))
    ) %>%
    forecast(h = 3) %>%
    accuracy(reference) %>%
    mutate(data = data_label)
}

resultat_tscv <- lav_tscv(lav_stretch(jernbanedata),
                          jernbanedata,
                          "Inkl. corona")
resultat_tscv_corona <- lav_tscv(lav_stretch(jernbanedata_corona),
                                 jernbanedata_corona,
                                 "Uden corona")

bind_rows(resultat_tscv, resultat_tscv_corona) %>%
  select(data, .model, key, RMSE, MAE, MAPE, MASE) %>%
  arrange(data, key, RMSE) %>%
  kbl(digits = 2, booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position"))
```

TSCV er den metodisk mest robuste evaluering. En central begrænsning er at ingen model opnår MASE < 1 på nogen kombination, Det er altså ikke alle modeller der slår SNAIVE benchmark modellen. Inkl. corona dominerer COVID kvartalerne fejlestimerne: RMSE på 762–934 (international) og 362–409 (Storebælt), MASE på 1,04–1,55. Uden corona er fejlene markant lavere, og MASE tættest på 1. ARIMA og SNAIVE er næsten identiske for

Tabel 30: TSCV-modelsammenligning inkl. og uden corona

[!h]	data	.model	key	RMSE	MAE	MAPE	MASE
	Inkl. corona	ETS	International trafik i alt	679,32	389,41	23,27	0,92
	Inkl. corona	ARIMA	International trafik i alt	769,70	484,83	26,35	1,15
	Inkl. corona	SNAIVE	International trafik i alt	929,59	532,93	34,73	1,26
	Inkl. corona	SNAIVE	Over Storebælt	360,41	236,66	16,46	1,37
	Inkl. corona	ETS	Over Storebælt	378,66	225,47	15,50	1,31
	Inkl. corona	ARIMA	Over Storebælt	387,45	253,77	16,59	1,47
	Uden corona	SNAIVE	International trafik i alt	259,98	191,78	5,09	1,01
	Uden corona	ARIMA	International trafik i alt	270,08	190,70	5,10	1,00
	Uden corona	ETS	International trafik i alt	277,06	194,70	5,12	1,02
	Uden corona	ETS	Over Storebælt	116,21	90,72	4,28	1,09
	Uden corona	ARIMA	Over Storebælt	124,77	100,32	4,71	1,21
	Uden corona	SNAIVE	Over Storebælt	128,76	100,65	4,73	1,21

international trafik (MASE=1,01) mens ETS marginalt er bedst for storebælt (RMSE = 120, MASE = 1,14). At MASE fortsat overstiger 1 skyldes sandsynligvis, at det stærke og konsistente sæsonmønster netop favoriserer SNAIVE. Corona perioden forringer evalueringsgrundlaget inkl. corona kraftigt, det interpolerede datasæt giver et mere retvisende billede af modellernes relative præstation.

```
lav_actuals <- function(data) {
  data %>%
    as_tibble() %>%
    select(kvartal, key, actual = x1000_passagerer)
}
```

```
actuals <- lav_actuals(jernbanedata)
actuals_corona <- lav_actuals(jernbanedata_corona)
```


```
lav_rmse_plot <- function(stretch, actuals_data, titel) {
  stretch %>%
    model(
      ARIMA = ARIMA(log(x1000_passagerer)),
      ETS = ETS(log(x1000_passagerer)),
      SNAIVE = SNAIVE(log(x1000_passagerer))
    ) %>%
    forecast(h = 3) %>%
    as_tibble() %>%
    group_by(.id, key, .model) %>%
    mutate(h = row_number()) %>%
    ungroup() %>%
    left_join(actuals_data, by = c("kvartal", "key")) %>%
    group_by(.model, key, h) %>%
    summarise(RMSE = sqrt(mean((.mean - actual)^2, na.rm = TRUE)),
              .groups = "drop") %>%
    ggplot(aes(x = h, y = RMSE, colour = .model)) +
    geom_line() +
    geom_point() +
    facet_wrap(~ key, scales = "free_y") +
    scale_x_continuous(breaks = 1:3,
                      labels = c("Q+1", "Q+2", "Q+3")) +
    labs(x = "Horisont",
```

```

    y = "RMSE",
    colour = "Model") +
    theme_minimal()
}

kør_begge(function(data, titel) {
  stretch <- lav_stretch(data)
  act <- lav_actuals(data)
  lav_rmse_plot(stretch, act, titel)
})

```



Figur 19: RMSE per forecast-horisont (h=1-4)

RMSE stiger med horisonten hvilket er forventet da usikkerheden akkumuleres over tid. Uden corona er RMSE markant lavere og modellerne præsterer mere stabilt på tværs af horisonterne.

9 Forecasting og prædiktion

```

kør_begge(function(data, titel) {
  data %>%
    model(
      ARIMA = ARIMA(log(x1000_passagerer)),
      ETS = ETS(log(x1000_passagerer))
    ) %>%
    forecast(h = 3) %>%
    autoplot(data %>% filter_index("2020 Q1" ~ .),
      level = c(80, 95)) +
    facet_wrap(~ key, scales = "free_y") +
    labs(y = "1.000 passagerer", x = NULL) +
    theme_minimal()
})

```

Tabel 31: NULL

```

lav_pred_tbl <- function(data, titel) {
  data %>%
    model(
      ARIMA = ARIMA(log(x1000_passagerer)),
      ETS    = ETS(log(x1000_passagerer))
    ) %>%
    forecast(h = 3) %>%
    hilo(level = c(80, 95)) %>%
    unpack_hilo(c("80%", "95%")) %>%
    select(key, .model, kvartal, .mean,
           `80%_lower`, `80%_upper`,
           `95%_lower`, `95%_upper`) %>%
    as_tibble() %>%
    kbl(digits = 0, booktabs = TRUE) %>%
    kable_styling(latex_options = c("striped", "hold_position")) %>%
    print()
  cat("\n\n")
}

kør_begge_tbl(lav_pred_tbl)

```


[!h]

key	.model	kvartal	.mean	80%_lower	80%_upper	95%_lower	95%_upper
International trafik i alt	ARIMA	2026 Q2	4274	3082	5615	2629	6582
International trafik i alt	ARIMA	2026 Q3	4266	2815	5948	2310	7250
International trafik i alt	ARIMA	2026 Q4	3900	2465	5587	1984	6939
International trafik i alt	ETS	2026 Q2	4756	3511	6146	3027	7127
International trafik i alt	ETS	2026 Q3	5664	3742	7891	3072	9613
International trafik i alt	ETS	2026 Q4	4979	3001	7339	2369	9299
Over Storebælt	ARIMA	2026 Q2	2284	1859	2743	1677	3041
Over Storebælt	ARIMA	2026 Q3	2233	1781	2724	1591	3049
Over Storebælt	ARIMA	2026 Q4	2239	1767	2755	1571	3098
Over Storebælt	ETS	2026 Q2	2391	1946	2871	1756	3182
Over Storebælt	ETS	2026 Q3	2490	1960	3069	1740	3456
Over Storebælt	ETS	2026 Q4	2579	1970	3252	1725	3713

NULL

[!h]

key	.model	kvartal	.mean	80%_lower	80%_upper	95%_lower	95%_upper
International trafik i alt	ARIMA	2026 Q2	5034	4688	5390	4518	5592
International trafik i alt	ARIMA	2026 Q3	5562	5062	6080	4822	6382
International trafik i alt	ARIMA	2026 Q4	4626	4211	5057	4011	5309
International trafik i alt	ETS	2026 Q2	4750	4422	5088	4260	5280
International trafik i alt	ETS	2026 Q3	5222	4838	5617	4651	5843
International trafik i alt	ETS	2026 Q4	4557	4205	4919	4034	5127
Over Storebælt	ARIMA	2026 Q2	2356	2244	2471	2187	2534
Over Storebælt	ARIMA	2026 Q3	2292	2159	2428	2092	2505
Over Storebælt	ARIMA	2026 Q4	2454	2300	2611	2224	2700
Over Storebælt	ETS	2026 Q2	2397	2276	2521	2215	2590
Over Storebælt	ETS	2026 Q3	2297	2161	2436	2094	2514
Over Storebælt	ETS	2026 Q4	2445	2283	2612	2203	2706



Figur 20: Forecast med prædiktionsintervaller (80% og 95%)

Forecasts er baseret på modeller estimeret på det fulde datasæt (2006Q1-2026Q1) med en horisont på fire kvartaler til 2027Q1. Log transformationen medfører assymetriske prædiktionsintervaller på originalskalaen (log normal fordeling) hvor opadrettede intervaller er bredere end nedadrettede. Intervallerne udvides med horisonten i takt med akkumuleret usikkerhed.

ARIMA & ETS er enige om retningen for begge serier, fortsat positiv vækst for international trafik i forlængelse af genopretningstrenden fra 2022 og mere stabil, moderat vækst for storeblælt konsistent med lavere trendstyrke. For international trafik er 80% & 95% prædiktionsintervallerne brede, konsistent med den højere modelusikkerhed afspejlet i ljung-box resultaterne.

10 Sammenfatning og konklusion

```
stl_features <- bind_rows(
  jernbanedata %>% features(x1000_passagerer, feat_stl) %>% mutate(data = "Inkl. corona"),
  jernbanedata_corona %>% features(x1000_passagerer, feat_stl) %>% mutate(data = "Uden corona")
) %>%
  select(key, data, trend_strength, seasonal_strength_year)

bedste <- resultat %>%
  filter(.type == "Test") %>%
  group_by(data, key) %>%
  slice_min(RMSE, n = 1) %>%
  select(key, data, Bedste_model = .model, MASE, RMSE)

sammenfatning <- stl_features %>%
  left_join(bedste, by = c("key", "data")) %>%
  mutate(
    COVID_impact = case_when(
      data == "Inkl. corona" ~ "Ja - ubehandlet",
      data == "Uden corona" ~ "Interpoleret"
    )
  )
```

Tabel 32: Sammenfatningsoversigt: Nøgletal per serie og datasæt

[!h]

Serie	datasæt	Trend	Sæson	COVID	Bedste_model	RMSE
International trafik i alt	Inkl. corona	0,97	0,81	Ja – ubehandlet	Auto	215,82
International trafik i alt	Uden corona	0,96	0,86	Interpoleret	M3	94,73
Over Storebælt	Inkl. corona	0,87	0,51	Ja – ubehandlet	M2	69,55
Over Storebælt	Uden corona	0,91	0,80	Interpoleret	M2	121,27

```

) %>%
select(
  Serie      = key,
  datasæt    = data,
  Trend      = trend_strength,
  Sæson      = seasonal_strength_year,
  COVID      = COVID_impact,
  Bedste_model,
  RMSE
) %>%
arrange(Serie, datasæt)

sammenfatning %>%
  kbl(digits = 2, booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position"))

```

Seriekarakteristika: Begge serier har stærke trendkomponenter (0,87-0,97). International trafik har den stærkeste sæsonstruktur (0,86 uden corona). Storebælt er mere afdæmpet sæsonstruktur (0,80) som forstyrres uforholdsmæssigt af corona. Guerrero analysen ($\lambda = 0$ på coronafri data) understøtter log transformation gennemgående.

Stationaritet: Coronaperioden svækker stationaritetsvurderingen. KPSS afviser ikke stationaritet inkl. corona, og auto ARIMA vælger $d=D=0$. Det interpolerede datasæt giver et mere korrekt grundlag, hvor $D=1$ vælges konsistent med den underliggende sæsontrend.

Modelpræstation: ETS opnår den laveste AICc & TSCV RMSE for international trafik inkl. corona (762) mod ARIMA (845). For storebælt uden corona (RMSE=120, MASE=1,14). Den exhaustive ARIMA søgning forbedrer AICc betydeligt, særligt for international trafik inkl. corona (5,4 til -4,8)

Residualanalyse: International trafik udviser vedvarende autokorrelerede residualer i begge modelklasser, og datasæt (Ljung-Box $p < 0,05$), hvilket antyder en dynamik uden for ARIMA/ETS rammens rækkevidde. Storebælt uden corona er den eneste kombination, hvor begge modeltypers residualtests består testen.

Benchmark og begrænsninger: Ingen af modellerne opnår $MASE < 1$ i TSCV, ingen slår SNAIVE. Inkl corona skyldes dette corona kvartaler som historiske mønstre ikke kan forudsige. Uden corona er MASE tæt på, men over 1. Corona interpolationen er analysens primære metodologiske forbehold, da interpolerede observationer er et skøn, og resultater på det rensede datasæt skal tolkes derefter.